干预、校准、发现：从像素学习因果结构

Ziyi Ding[1,5,*] Xiaodi Huang[2,*] Xianxin Lai[3,5] Haijier Chen[4,5]
Zhang Zhang[2] Xiao-Ping Zhang[1,†] Jiayu Chen[3,5,†]

[1]Tsinghua University
[2]Institute of Automation, Chinese Academy of Sciences
[3]The University of Hong Kong [4]Wuhan University
[5]INFIFORCE Intelligent Technology, China

[*]Equal contribution. [†]Corresponding authors.
xpzhang@ieee.org jiayuc@hku.hk

Project website dzyy123.github.io/intervene-calibrate-discover/

Abstract

从低层观测中学习高层因果变量，是人工智能的一个核心问题 (Schölkopf et al., 2021)。本文研究已知节点语义、未知因果图下的干预查询：视觉读数误差可能使模型中的设定与环境操作值不一致。我们冻结编码器与解码器，用固定轮转干预采集的核验执行值学习逐维可逆校准；随后冻结映射，以主动实验确定图方向、局部机制预测后果，并经逆校准解码。在多米诺、抓取放置、平衡、Gears、CAUSAL3D 及 CausalWorld 上，我们评价图发现、干预后果预测与反事实图像生成。受控多米诺实验表明，干预可消除等量追加观测仍保留的方向歧义。在同数据多米诺对照中，我们进一步预测同一事实情境下改变操作对其他变量的影响；校准后的平均误差低于未校准模型。

1 引言

智能体看到一幅图片后，能否预测按指定值操作一个对象会产生什么后果？以图 1中的多米诺场景为例，预测改变骨牌状态后的结果，既需要从像素估计状态，也需要判断作用会沿哪些关系传递。图像重构回答画面包含什么，干预查询还要求模型理解操作改变了哪个变量、把它设成了什么值，以及其他变量如何响应 (Schölkopf et al., 2021)。这一区别与物理系统的反事实预测 (Li et al., 2020) 和环境变化下的机器人迁移 (Ahmed et al., 2021) 直接相关。

本文的核心目标是：让从像素得到的因果变量，能够按照真实环境中的操作值执行干预查询。观测中方向不同的图可能具有相同条件独立关系，形成马尔可夫等价类（Markov equivalence class, MEC）。在第 3节的条件下，智能体可选择目标并采集干预响应来区分候选图；干预覆盖与识别条件充分时才可能确定唯一图 (Hauser & Bühlmann, 2012)。

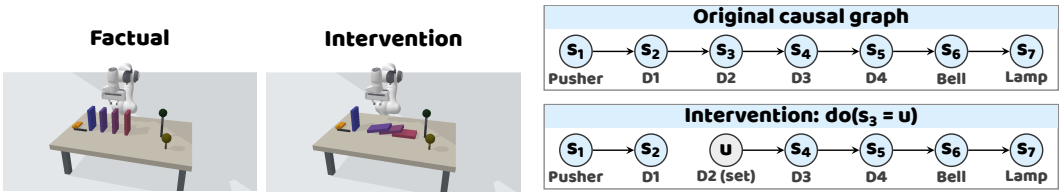


图 1: 左：模拟器中第二块骨牌从 20° 倾角释放前后的场景，机械臂为固定场景部件。右：独立定义的七节点结构因果模型（SCM）示意（推动器、四块骨牌、铃、灯）；do($s_3 = u$) 替换目标机制并移除其入边。左侧物理预览不是模型预测，也不作为右侧七节点图的验证结果。

知道变量对应哪个对象，不等于知道如何按真实操作值设定它。概念标签可以使潜变量 z_j 对应目标状态 s_j，但观测监督训练后的编码器仍可能存在尺度、偏置或非线性估计误差。同

一个数值在视觉坐标与环境中因而可能表示不同状态；即使图方向正确，错误的目标设定也会影响后果计算。“真实操作值”指环境中核验后实际达到的目标值；查询以有效目标设定为条件，执行器如何达到该值不属于所求模型。

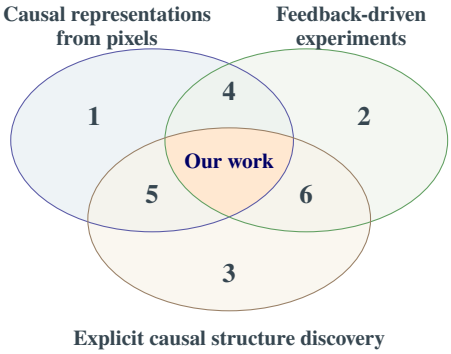
校准阶段按固定轮转采集核验执行值与响应图片，只监督直接目标，在冻结编码器与解码器时学习可逆映射 T。随后冻结 T，由观测构建部分图，再按未定向关系选择实验，在总预算内修订方向。图与局部机制形成结构因果模型（structural causal model, SCM）：校准连接操作单位，干预提供方向证据，机制传播非目标后果。

本文贡献。 本文以直接目标的核验值监督可逆映射 T，修正已对齐视觉读数与操作值的数值偏差，不更新原视觉模型。目标设定、图发现与机制拟合使用同一坐标，预测结果经 T^{-1} 返回解码器。在估计图有效且充分定向时，可查询非目标节点的干预均值，以及给定事实图片的反事实图像。

2 相关工作

图 2区分因果变量识别、实验选择与本文的操作值校准问题。

视觉因果表征。 CausalVAE 从概念监督学习结构化表示，支持潜变量干预后的图像生成 (Yang et al., 2021)。CITRIS 利用已知干预目标与时序图片识别变量，也可在预训练自编码器后学习可逆变换；iCITRIS 处理瞬时作用，BISCUIT 学习变量与二值交互机制的对应 (Lippe et al., 2022; 2023b;a)。隐式潜在因果模型（ILCM）从干预前后配对样本学习变量并支持结构提取 (Brehmer et al., 2022)；干预约束表征识别也已有理论研究 (Ahuja et al., 2023)。这些能力并不自动确定变量数值与环境操作值的对应。本文在节点身份已知后，用核验执行值校准尺度、偏置或非线性读数误差，以处理目标设定失准及其对后果查询的影响。



1 Ahuja et al. (2023)
2 Causal Curiosity Sontakke et al. (2021)
3 PC-stable Colombo & Maathuis (2014) GIES: Hauser & Bühlmann (2012)
4 ICF Thomas et al. (2018)
5 CausalVAE: Yang et al. (2021) CITRIS: Lippe et al. (2022)
6 AIT: Scherrer et al. (2021) CBED: Tigas et al. (2022)

图 2: **面向操作值查询的研究位置。**三个集合概括输入、采集与结构学习方式；本文具体处理视觉估计与核验操作值的数值对齐。中心交集表示联合任务设置，不表示性能排名。编号对应代表性工作，分类条件见附录 H.1。

主动实验与可控因素。 Causal Curiosity 通过实验行为区分环境因素；独立可控因素（ICF）学习可被不同操作单独改变的视觉因素 (Sontakke et al., 2021; Thomas et al., 2018)。变量已定义时，主动干预策略与 AIT 选择目标，因果贝叶斯实验设计（CBED）还选择设定值，CAASL 使用预训练选实验策略 (Hauser & Bühlmann, 2014; Scherrer et al., 2021; Tigas et al., 2022; Annadani et al., 2024)。结构化变量上的主动发现解决如何收集结构证据，视觉读数的数值校准仍须单独处理。本文按固定轮转采集校准记录，冻结映射后再以覆盖未定向边的策略选靶，使图发现与机制拟合使用同一操作值坐标。

基于操作响应的坐标对齐。 Rep4Ex 利用动作–潜变量不变性进行干预外推 (Saengkyongam et al., 2024)。Ding 等以 CausalVAE 世界模型插件研究反事实检索，在状态监督可用时于训练中进行对齐 (Ding et al., 2026)。本文用核验值校准冻结视觉模型中的已知节点，以相同数据下充分拟合的仿射对照检验非线性校准的额外收益。

3 问题定义

我们研究可交互环境中的操作值查询：给定目标 j 及环境中的设定值 u，从视觉观测学得模型并预测其后果。变量描述操作后的*结算状态*，而非逐帧动力学。学习者已知节点语义，但不知道直接作用图或结构方程。真实状态、图像观测与模型坐标定义如下，术语见附录 A.4。

环境与真实变量。 令 $V = \{1, \dots, K\}$ 为节点集合，$s = (s_1, \dots, s_K) \in \prod_j \mathcal{S}_j \subseteq \mathbb{R}^K$ 为状态向量；$\mathcal{S}_j$ 为第 j 个状态的取值域，二值事件取 $\{0, 1\}$，连续状态取相应实数区间。未知图 $G^\star = (V, \mathcal{E}^\star)$ 的有向边集为 $\mathcal{E}^\star$，$\mathrm{Pa}_G(j)$ 表示直接父节点。结构方程 $f_j^\star$ 与外生扰动 $\epsilon = (\epsilon_1, \dots, \epsilon_K) \sim P_\epsilon$ 生成状态和图片：

$$s_j = f_j^\star(s_{\mathrm{Pa}_{G^\star}(j)}, \epsilon_j), \qquad x = R(s, \nu) \in [0, 1]^{H \times W \times 3}. \tag{1}$$

R 为环境的观测函数，ν 表示外观等成像因素，H, W 为图像尺寸。R 与 $f_j^\star$ 不供学习者生成预测；模拟器真状态、真图及配对图片仅按协议用于监督或评价。上标 $\star$ 表示真实环境对象，帽号表示估计量。

已知输入与监督权限。 输入为观测训练集 $\mathcal{D}_{\text{obs}} = \{(x_i, \ell_i)\}_{i=1}^{N_{\text{obs}}}$、允许干预的目标集合 $\mathcal{J} \subseteq V$ 及各目标的可行值域 $\mathcal{U}_j$。标签 $\ell_i \in \mathbb{R}^K$ 提供状态的数值监督及维度身份，不提供 $\mathcal{E}^\star$。因此，$z_j = E_\theta(x)_j$ 与 s_j 的对应关系来自监督，而非无监督潜因子识别。单帧不可辨别的状态须由协议提供额外帧或动作信息，并对比较方法开放相同权限。

s_j 是真实状态，z_j 是编码器估计，h_j 是 $T_j(z_j)$ 经观测统计量标准化后的读数。z 是 decoder 的训练坐标，h 用于图检验与机制拟合；二者均含视觉估计误差。T_j 只修正已对应维度的数值关系，不学习节点置换或跨维混合。环境值 u 经单位转换得到同坐标下的模型设定值 $q_j(u)$，见式 (5)。图片先经编码与校准，操作值则直接换算单位；操作值不再通过 T。

环境干预与预算。 $a = (j, u)$ 指定目标 $j \in \mathcal{J}$ 和核验后实际达到的值 $u \in \mathcal{U}_j$。硬干预 $\mathrm{do}(s_j = u)$ 替换该节点的生成机制，其余机制保持不变：

$$s_j^a = u, \qquad s_k^a = f_k^\star(s^a_{\mathrm{Pa}_{G^\star}(k)}, \epsilon_k) \quad (k \neq j). \tag{2}$$

环境返回 (j, u, x^{int})，不返回全部真实状态。u 须是与图像所表示状态相对应的核验值，而非未经检查的控制指令；释放动作或软干预能否实现上述机制替换，需要各任务单独定义。给定无环图，式 (2)按拓扑次序求值。总体干预预测沿用同一外生分布，个体反事实则固定事实情境中的 (ϵ, ν)。仅筛选 $s_j = u$ 的观测样本并不替换机制，因此不同于干预。

总交互预算 $B = B_{\text{cal}} + B_{\text{graph}}$ 包含校准与图发现的新环境记录；重放不重复计费，提前停止另报实际消耗。观测训练数据量单列。主动采集的目标依赖已收集证据，不同目标的自适应记录不视为同一观测分布的独立同分布样本。

识别条件与适用边界。 假设 $G^\star$ 为 DAG，所研究变量间无遗漏共同原因，$P_\epsilon = \prod_j P_{\epsilon_j}$，且不存在选择偏差；观测状态分布满足因果 Markov 条件与忠实性。单目标干预不改变非目标机制及外生分布 (Colombo & Maathuis, 2014; Hauser & Bühlmann, 2012)。为定义均值及平方误差，相关状态具有有限二阶矩；用于标准化的训练变量须有非零方差。这些是对环境和数据的条件，不是视觉编码器训练自动满足的性质。视觉误差、近似独立性检验或不充分的干预覆盖都可能阻碍图恢复。逐维可逆 T 本身不新增总体条件独立信息；唯一真图恢复仅在额外的充分识别条件下成立。

校准适用于所选逐维单调函数能够近似其数值偏差、且该关系跨观测与干预图片稳定的视觉接口。未被直接操作的维度不接收目标执行值监督，其映射仅由观测保持项约束。

求解目标。 在上述输入与预算下，学习编码器 E_θ、校准映射 $T_{\widehat{\phi}}$、图 $\widehat{G}$、局部机制 $\widehat{f}_j$ 及解码器 D_ψ，以节点设定计算非目标响应。参数与标准化统计量只用允许的训练数据，测试时冻结；完整模型记法及拟合残差见附录 A.5。

(1) 结构识别：比较 $\widehat{G}$ 与 $G^\star$ 的直接邻接和方向，以检验后果传播的结构依据；证据不足时保留部分图。**(2) 干预后果预测**：给定操作 $a = (j, u)$，将节点 j 设为核验值 u，预测其他节点在不同情境中的平均结算状态。对每个非目标节点 k，定义干预均值

$$\mu_k(j, u) = \mathbb{E}[s_k \mid \mathrm{do}(s_j = u)] = \mathbb{E}_{\epsilon \sim P_\epsilon}[s_k^a(\epsilon)], \qquad k \neq j.$$

这里 $\mathbb{E}[\cdot \mid \mathrm{do}(s_j = u)]$ 表示干预分布下的期望，不是筛选 $s_j = u$ 的观测条件均值；$s_k^a(\epsilon)$ 由式 (2)给出。模型估计量记为 $\widehat{\mu}_k(j, u)$，对不同情境取平均，不以某张事实图片为条件。它是单一干预下的状态均值，不是比较两个设定的平均处理效应。$k \neq j$ 排除已被直接设定的目

标，以评价后果传播而非命令复制。分布内（in-distribution, ID）与分布外（out-of-distribution, OOD）由各任务训练与测试分布定义。**(3) 反事实图像生成**：给定事实图片 x 和替代命令 a，输出 $\widehat{x}^{\mathrm{cf}}(x,a)$，与固定事实情境的模拟器重放结果比较。单张图片未必唯一确定 (ϵ,ν)，故配对评价不等于证明个体反事实可识别。需要 DAG 的机制拟合与查询仅在估计图有效且充分定向时执行。

4 方法

为实现上述求解目标，我们分三步建立从图片到操作后果的预测模型（图 3）。**第一步，学习并校准视觉读数**。以概念监督建立潜变量与节点的对应关系，随后冻结编码器和解码器，按固定轮转采集核验执行值，只更新逐维校准映射 T。**第二步，确定后果传播的结构**。冻结 T，以观测数据估计候选骨架，再主动选择目标实施环境干预，用响应证据定向。**第三步，预测状态并生成图像**。在有效且充分定向的图上拟合局部机制，分别计算不同情境下的干预均值和给定事实图片的反事实；生成图像时经逆校准返回解码器坐标。测试时全部模块冻结，查询坐标见附录图 A2。

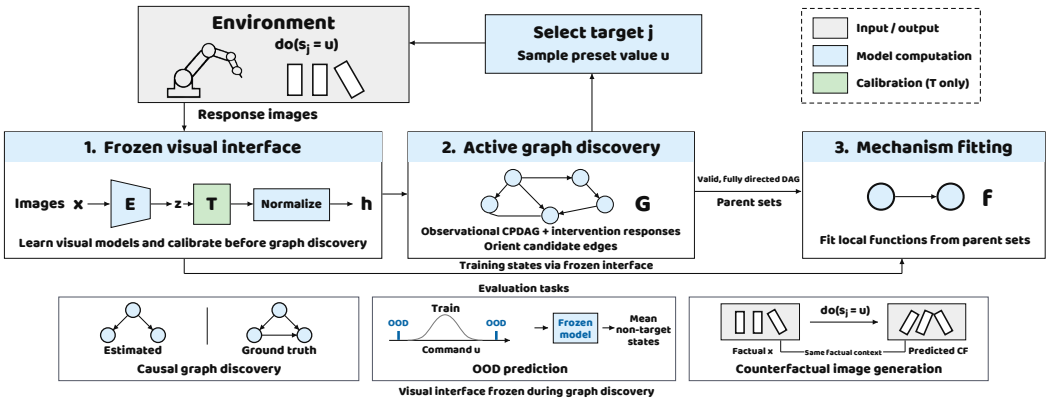


图 3: 完整学习流程与三项评价。视觉模型与校准先学习并冻结，再主动选靶、定向和拟合机制。E, T, G, f 为编码器、校准、估计图和机制；灰、蓝、绿表示输入/输出、计算和校准。OOD 分支仅指已定义变化轴的任务，不含主表仅作 A/B 测试的列；曲线为连续命令示意。查询坐标见附录图 A2。

4.1 节点对齐的视觉学习与读数校准

概念监督的变分自编码器学习重构，并以标准化状态标签约束潜变量身份（附录 B.3）。冻结编码器后取后验均值 $z = E_\theta(x)$；联合训练的解码器 D 可仅用 ID 重构后拟合为 D'。校准只更新 T，同一对照内部共用 D 或 D'。

以核验目标状态监督数值校准。 对目标 j，核验执行值 u 和干预图片的编码 $E_\theta(x^{\mathrm{int}})_j$ 描述同一状态。我们利用这一配对监督估计偏差，保持既有的维度身份。令 μ_j^s, σ_j^s 为节点 j 在观测训练标签中的均值和标准差，$\alpha_j(u) = (u - \mu_j^s)/\sigma_j^s$ 将实际设定值转到训练锚点单位。上标 s 区分固定的训练标签均值 μ_j^s 与随操作 (j,u) 变化的干预均值 $\mu_k(j,u)$。对校准记录 (j, u, x^{int})，拟合逐维严格单调映射

$$T_{\phi,j}(z_j) = g_j z_j + b_j + \sum_{l=1}^{L} w_{jl} \tanh(z_j - \kappa_l), \qquad g_j > \sum_l |w_{jl}|. \tag{3}$$

ϕ 包含尺度 g_j、偏置 b_j 与权重 w_{jl}；κ_l 为 L 个双曲正切基函数的固定结点，约束确保可逆性。$\mathcal{D}_{\mathrm{cal}}$ 为校准记录集，$\lambda \geq 0$ 权衡目标监督与观测表示保持。以下期望均为有限记录集上的经验平均:

$$\mathcal{L}_{\mathrm{cal}} = \mathbb{E}_{(j,u,x^{\mathrm{int}})\sim\mathcal{D}_{\mathrm{cal}}}\left[(T_{\phi,j}(E_\theta(x^{\mathrm{int}})_j) - \alpha_j(u))^2\right] + \lambda \mathbb{E}_{x\sim\mathcal{D}_{\mathrm{obs}}} \frac{\|T_\phi(E_\theta(x)) - E_\theta(x)\|_2^2}{K}. \tag{4}$$

第一项约束目标潜变量接近标准化核验值，第二项限制观测表示的漂移；非目标变量不以 u 监督。按固定轮转采集、重放累计证据，在预定轮次结束后冻结 $T = T_{\widehat{\phi}}$。记 $\widehat{\phi}$ 为拟合结束时的参数，以训练观测计算校准读数的逐维均值 μ^c 和标准差 σ^c，定义统一接口

$$h(x) = \frac{T(E_\theta(x)) - \mu^c}{\sigma^c}, \qquad q_j(u) = \frac{\alpha_j(u) - \mu_j^c}{\sigma_j^c}. \tag{5}$$

$h_j(x)$ 是标准化校准估计，$q_j(u)$ 是同坐标下的目标设定值；除法按元素进行。T 修正视觉读数，核验值直接经 α_j 与标准化转换，不重复通过 T。训练与测试共用冻结变换，以 $q_j(u)$ 设定模型节点，逐维映射保持节点身份。该映射用于观测或其他目标干预图片时，要求读数误差关系跨来源稳定；这一条件须独立检验，不能由目标监督或单调性推出。

4.2 观测结构与主动定向

PC 类方法在 $h(\mathcal{D}_{\text{obs}})$ 上检验条件独立，目标是以完全部分有向无环图（CPDAG）表示观测等价类 (Colombo & Maathuis, 2014)；有限样本输出 $\widehat{G}_0$ 仍可能错误。RGB 多米诺采用线性偏相关，各 MEC 后端见附录 C.1。

每轮从尚有采集额度的目标中，选择连接最多未定向边的节点；平分规则与 ID 设定值分布均预先固定，不读取真图或测试结果（附录 B.3）。新图片经过冻结的 h。RGB 多米诺对候选邻接使用单目标记录 $\mathcal{I}_j$ 上的响应分数

$$e_{j\to k} = \left|\widehat{\text{Corr}}(h_j, h_k; \mathcal{I}_j)\right|. \tag{6}$$

$\widehat{\text{Corr}}$ 为样本相关系数。该分数仅为初始候选邻接提供定向证据，不是直接因果效应估计；目标仍使用视觉估计而非命令替代。依据双侧响应、阈值 $\tau = 0.15$ 与差距 $\delta = 0.05$ 提出方向，通过冲突及无环性检查后应用 Meek 传播 (Meek, 1995)。样本量门槛、单侧规则及拒绝条件见附录 B.1；预算耗尽时保留未解决方向。

定向要求可靠邻接与可检测响应。弱相关不能排除非线性效应，图一致性检查也不保证统计判断正确。附录 B.7检验边遍历顺序的影响与无效证据保护。

4.3 局部机制估计与新命令预测

在有效且充分定向的估计图上，以父节点的 h 读数为输入，通过带截距的岭回归拟合局部机制 $\widehat{f}_j$（附录 B.3）。拟合 j 时排除直接干预 j 的记录，因为其机制已被替换；根节点观测值与拟合残差存为样本池。逐维可逆性不保证校准后的关系线性：非线性 T 也可能改变关系形状及残差与父状态的依赖。因此分别评价读数、传播后果和反事实（附录 B.6）。

新命令下的分布后果预测。 给定 $a = (j, u)$，以 $q_j(u)$ 替换目标值，从训练根节点与残差池重采样并沿图传播。各样本还原标签单位后，对每个非目标节点 $k \neq j$ 取状态均值，得到 $\widehat{\mu}_k(j, u)$。图片须经逆校准、逐样本解码后平均，不能直接解码平均潜变量。单位转换与采样式 (18)见附录 B.4。

4.4 Decoder 与反事实图像生成

反事实生成固定事实情境，预测替换目标操作后的图像。输入为事实图片 x 及干预操作 $a = (j, u)$，编码、校准和归一化得到 $h(x)$。SCM 更新目标及其后代，其他坐标保留事实值，再由解码器生成图片；重构能力不能替代正确的节点设定与机制传播。

对每个非根节点，从事实 x 估计 $\eta_j^{\text{fact}} = h_j(x) - \widehat{f}_j(h_{\text{Pa}_{\widehat{G}}(j)}(x))$，固定事实残差，替换目标为 $q_j(u)$ 并更新后代，得到反事实潜状态 h^{cf}。非目标根节点及目标之外的非后代保留事实读数。此时结果处于 h 坐标，而解码器在 z 坐标上训练，因此先撤销标准化，再逆转校准，最后解码：

$$\widehat{x}^{\text{cf}} = D_\psi\left[T^{-1}\left(\sigma^c \odot h^{\text{cf}} + \mu^c\right)\right]. \tag{7}$$

$\widehat{x}^{\text{cf}}$ 为预测反事实图片，T^{-1} 为冻结校准映射的逆，$\odot$ 表示逐元素乘法。估计残差不等同于真实外生原因。附录 B.4另述单独评价的恒等校准、条件均值配置，其不加回事实残差。

5 实验

实验证据对应三个环节：干预消除等量追加观测仍保留的方向歧义；同数据校准在受控多米诺组中降低平均干预效应误差；状态与图像查询检验下游用途。系统比较评价任务表现，不单独归因于某个组件；仅改变 decoder 的对照区分渲染收益与校准作用。协议及统计索引见附录 A.1。

5.1 实验设置

Benchmarks。 任务包括多米诺骨牌、抓取放置（PnP）、平衡（Balance）、齿轮传动（Gears）、CAUSAL3D 的 Spring 与 Seesaw(Liu et al., 2025) 及 CausalWorld(Ahmed et al., 2021)。多米诺单列七节点连续 SCM 与四节点接触动力学实现；后者用二值事件 F_i 表示骨牌是否倾倒，评价固定/释放命令下的同初态重放。PnP、Balance、Gears 分别含六、五、六个 SCM 变量。图 4展示场景；多米诺配置和主表范围分别见附录 A.9、A.3。

Baselines。 系统比较采用 CausalVAE(Yang et al., 2021) 与从干预配对图片学习的 ILCM(Brehmer et al., 2022)，使用各自表示、图提取、潜变量干预与 decoder。ICM-VAE 是给定图的生成参考 (Komanduri et al., 2024)；无图对照通过各实验组的算子移除依赖（附录 B.2）。ID 质量及模型选择见附录 G.2，不将基线弱表现归结为没有干预。

评价标准。 图发现报告 SHD↓（反向计一次）与 AUPRC↑；后果预测报告按训练尺度归一化的非目标状态均值 NMSE↓；反事实报告 RGB MSE↓。反事实模型仅接收事实图与命令，GT 由同外生情境或物理初态重放；总体预测则只接收命令。后两表误差乘 10^3。流程完成、图恢复与查询可执行的分母分别定义（附录 A.6）。

比较范围。 三张主表中的本文方法采用学习型 T；统一比较、给定图参考及不同权限物理 ILCM 分别列明（附录 A.2）。这些描述性指标只衡量已执行查询的条件误差，不代表端到端成功率或共同查询总体上的优势。连续任务列保留所报告的 ID/幅值变化标签，其余列作 A/B 测试（附录 A.8）。浅蓝标本文方法，粗体标最优点估计；“–”为不适用。采集效率计总预算 $B = B_{\text{cal}} + B_{\text{graph}}$。

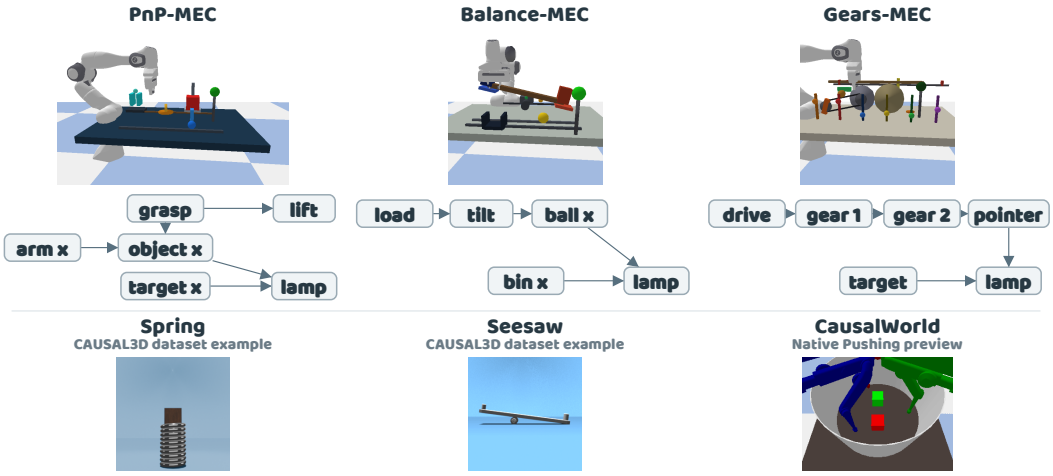


图 4: 实验环境示例。上排为 PnP、Balance、Gears 的受控 MEC 场景及生成图；下排为 CAUSAL3D 的 Spring、Seesaw 原图与 CausalWorld 原生 Pushing 场景示意。生成图不是估计结果，场景示意不表示主表配置或模型预测；来源见附录 A.7。

5.2 通过环境干预发现因果图

共享视觉与校准接口的三种子对照按相同新增记录数比较图发现：两种干预采集策略用 1800 或 3600 条记录均恢复真图，等量追加观测仍保留 6 条未定向边。在该受控任务中，消

除剩余方向歧义需要干预响应，增加等量观测不能替代；覆盖选靶未比轮转节省记录。协议及不同定向判据的诊断见附录 C.2、C.1。

表 1: 图发现比较：每格上/下行为 SHD↓/AUPRC↑。粗体标最优点估计，浅蓝标识本文方法。下部为流程完成数/计划种子数，不表示图恢复率；比较范围见附录 G.1。

	多米诺骨牌		其他 MEC 任务			CAUSAL3D		Causal World
方法	SCM	物理仿真	PnP	Balance	Gears	Spring	Seesaw	
	4	**0**	**0**	6	7	**9**	**5**	**4**
本文方法	**.846**	**.982**	**.862**	.413	**.793**	**.242**	**.587**	**.276**
	6	3	3	8	8	11	7	11
CausalVAE	.313	.284	.516	**.475**	.522	.213	.342	.013
	6	2	5	**4**	**5**	17	8	16
ILCM	.194	.294	.232	.178	.177	.084	.231	.007
流程完成数/计划种子数↑（非图恢复率）								
本文方法	8/8	7/8	8/8	7/8	8/8	8/8	6/8	7/8

表 1中，本文方法的 SHD 在八列中六列最优、AUPRC 在七列最优，物理多米诺与 PnP 的 SHD 为 0。完整系统在多数任务上获得更准确的结构估计，而上述同接口对照说明，图阶段的干预响应提供了追加观测仍缺少的定向证据。优势并非覆盖所有指标：Balance 与 Gears 的 SHD 高于 ILCM，Spring、CausalWorld 的 AUPRC 为 0.242、0.276，完整结构恢复仍有较大误差。

5.3 操作值校准与干预效应

表 2在七节点多米诺场景（64×64 彩色图像）的同一三种子组中比较读数、非目标 CF 效应和 RGB 误差。每种子各配置共享测试情境与命令；前三行共用 ID 后拟合 D'，普通联合更新另训练读出头与 decoder，仅作不同权限参考。CF 效应比较事实差分，不与总体均值 NMSE 混用。

表 2: 同一三种子配对组的操作读数、干预效应与图像，误差乘 10^3，均值 $\pm$ 种子样本 SD。前三行共用各自种子的冻结 encoder、数据、已学图与 ID 后拟合 D'，按各自坐标拟合机制；普通更新另训练读出头与 decoder，仅作参考。全部种子 5/6/7 计分，粗体标前三行最低均值；配对差见附录 D.4。

	ID 读数	非目标 CF 效应 NMSE↓		RGB MSE↓	
配置	MSE↓	ID	幅值变化	ID	幅值变化
无校准	22.367 ± 3.941	5.463 ± 0.946	6.858 ± 1.290	1.085 ± 0.066	0.874 ± 0.046
充分拟合仿射	14.721 ± 1.177	$\mathbf{4.763} \pm 0.142$	6.656 ± 0.531	$\mathbf{1.043} \pm 0.065$	$\mathbf{0.856} \pm 0.034$
本文非线性校准	$\mathbf{12.864} \pm 0.830$	4.968 ± 0.123	$\mathbf{6.515} \pm 0.418$	1.065 ± 0.063	0.878 ± 0.036
普通联合更新（参考）	11.361 ± 5.044	9.985 ± 1.611	20.449 ± 3.725	1.058 ± 0.080	0.851 ± 0.053

操作值校准使视觉读数与目标设定共享单位，其有效性需要通过干预后果检验，不能只看状态读数 MSE。普通联合更新的平均读数误差 11.361 低于非线性校准的 12.864，但 ID/幅值效应误差 9.985/20.449 高于 4.968/6.515。普通更新同时改变读出头和 decoder，因此该比较不单独证明可逆性的贡献。

非线性校准的两种效应均值低于无校准，各有 2/3 种子改善；相对仿射，幅值效应更低而 ID 效应及 RGB 更高。这支持校准在本组实验中降低平均干预效应误差，但不支持非线性形式对所有查询都占优。Gears 固定图两种子也出现读数略改善、查询误差升高（附录 D.4）。效应定义与同组统计口径见附录 D.1。

5.4 干预后果预测与分布变化

本节冻结模型，预测操作 (j, u) 下其他变量的平均结算状态。表 3区分所报告的 ID/幅值变化列与 A/B 测试，分别给出两组绝对 NMSE 及其比值 r。本表第二组误差均不小于第一组；r 越接近 1 表示相对增长越小，但提高第一组误差也能提高 r，故须结合绝对误差解读。

表 3: 干预后果预测的条件误差，不含阻断查询。未标 † 列保留所报告的 ID/幅值变化标签，依次为 NMSE（乘 10^3）及其比值 r；† 列为测试集 A、B 及 E_A/E_B，不推断 OOD 类型。粗体标列出的最低误差汇总，浅蓝标本文方法；误差越低越好，r 不能单独排名。比较范围及分布解释见附录 A.2、A.8。

	多米诺骨牌		其他 MEC 任务			CAUSAL3D		Causal World
方法	SCM	物理仿真 †	PnP	Balance	Gears	Spring†	Seesaw†	†
	8.573	**6.234**	**1.771**	**2.085**	**.729**	**5.323**	**4.276**	**4.817**
	10.341	**8.291**	**3.461**	**4.101**	**1.091**	**8.064**	**6.786**	**5.378**
本文方法	**0.829**	**0.752**	**0.512**	**0.508**	**0.668**	**0.660**	**0.630**	**0.896**
	123.799	228.713	51.105	130.996	75.124	186.127	156.435	293.854
	807.120	791.706	318.545	852.155	503.839	609.486	987.345	974.245
CausalVAE	0.153	0.289	0.160	0.154	0.149	0.305	0.158	0.302
	123.713	162.410	58.106	104.107	101.258	234.144	95.245	124.215
	874.392	515.288	394.825	713.652	699.789	772.011	312.261	332.211
ILCM	0.141	0.315	0.147	0.146	0.145	0.303	0.305	0.374
	34.144	51.205	57.011	102.146	93.292	204.114	98.701	41.124
	245.391	421.363	393.035	700.012	663.595	402.341	244.512	408.946
无图消融	0.139	0.122	0.145	0.146	0.141	0.507	0.404	0.101

对已执行查询，本文方法在八列的两组误差点估计均最低，r 为 0.508–0.896；基线与无图消融为 0.101–0.507。相对于各列 CausalVAE/ILCM 的较低条目，所报告第二组条件误差的算术差幅约为 97.8%–99.8%。该差距描述所列实现和测试集，不等同于端到端成功率或相同幅度的 OOD 优势；分布定义与 ID 拟合质量须一并解释。

无图行在所有列的第二组误差均更高。这是实验组特定的依赖消融，不一定是保持机制参数不变的传播开关（附录 B.2）。第 5.3节的事实条件效应 NMSE 与此处总体均值误差对应不同查询。

5.5 反事实 RGB 图像生成

本节固定事实情境，经潜变量干预与各自 decoder 生成图片。在表 4所报告的汇总中，本文方法八列有七列像素 MSE 数值最低：PnP 相对 CausalVAE 低 68.6%，Spring 相对 ILCM 低 26.8%；Seesaw 则高 57.9%。整图 MSE 同时包含重构与后果误差；因果解释须结合非目标状态效应及独立读图的目标执行、后代响应和非后代保持，不能由图片更清晰单独推出。

表 4: 反事实 RGB 图像生成：像素 MSE↓（$\times 10^{-3}$），仅计已执行查询，不含阻断项。粗体标列出的最低汇总值，浅蓝标本文方法，“–”为不适用。物理 ILCM 为不同权限与预算的单种子参考，不参与统一排名；比较范围见附录 A.2。

	多米诺骨牌		其他 MEC 任务			CAUSAL3D		Causal World
方法	SCM	物理仿真	PnP	Balance	Gears	Spring	Seesaw	
本文方法	**1.473**	**.880**	**1.118**	**2.180**	**.938**	**2.384**	8.264	**5.261**
CausalVAE	2.525	1.287	3.563	4.603	1.859	6.345	11.745	7.761
ILCM	9.009	5.707	7.025	15.477	8.187	3.256	**5.234**	9.664
ICM-VAE（给定图）	–	–	–	–	–	7.342	9.753	–
无图消融	4.215	2.314	2.161	5.014	1.859	15.234	32.219	19.281

图 5A 概括正文的反事实计算路径，B 展示同一物理情境下无校准条件均值对照与 CausalVAE、ILCM 的图像及局部误差；B 中的实测图片并非 A 路径的输出。学习型校准与事实残差的配对图见附录图 A4，独立读图评价见附录 D.3。

解码器配对对照。 仅将原 D 改为 ID 后拟合 D'，幅值 CF 像素 MSE 降低 49.32%（3/3），状态预测不变，无校准与仿射也受益（附录 E.1）；表 2则共用 D' 比较校准。其他组件及预算对照见附录 F.3。

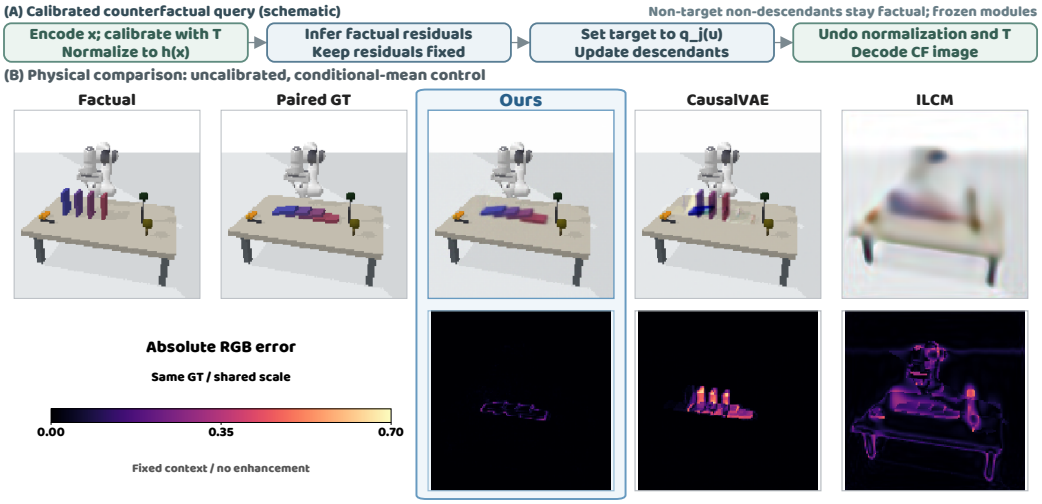


图 5: (A) 学习型校准、事实残差传播与逆校准解码的计算示意。(B) 令第一块骨牌倾倒（$F_1 = 1$）的物理场景比较，浅蓝框为无校准条件均值对照。事实图、配对 GT 与模型输出列于上排，下排 RGB 平均绝对差共用色阶；图片仅作 $[0, 1]$ 显示裁剪。ILCM 为不同训练权限的单种子参考，见附录 A.9。

6 结论

本文在已知节点语义下，以核验操作值校准视觉读数，使节点设定、因果机制与解码接口使用一致的操作单位。匹配对照支持校准能够改善部分干预查询，但仿射与非线性的相对效果依赖具体条件，读数改善不自动推出下游改善。环境干预提供了追加观测缺少的方向信息；这一结论与选靶效率、图像重构收益分别成立。

AI 使用说明

生成式 AI 工具用于辅助结果分析、写作与翻译、方法与实验讨论、代码实现及图示制作。AI 辅助的分析随后由作者进行人工校对。研究动机、方法设计及科学决策由作者主导，作者对实验、所报告的结果和最终稿件承担责任。

可复现性说明

实验设置、评价协议和分项结果见附录。附录 A.2汇总比较权限与统计单位；各项设置与结果均按其所属实验组解释。

参考文献

Ossama Ahmed, Frederik Träuble, Anirudh Goyal, Alexander Neitz, Yoshua Bengio, Bernhard Schölkopf, Manuel Wüthrich, and Stefan Bauer. CausalWorld: A robotic manipulation benchmark for causal structure and transfer learning. In *International Conference on Learning Representations*, 2021. URL https://openreview.net/forum?id=SK7A5pdrgov.

Kartik Ahuja, Divyat Mahajan, Yixin Wang, and Yoshua Bengio. Interventional causal representation learning. In *Proceedings of the 40th International Conference on Machine Learning*, volume 202, pp. 372–407. PMLR, 2023. URL https://proceedings.mlr.press/v202/ahuja23a.html.

Yashas Annadani, Panagiotis Tigas, Stefan Bauer, and Adam Foster. Amortized active causal induction with deep reinforcement learning. In *Advances in Neural Information Processing Systems*, volume 37, 2024. doi: 10.52202/079017-1403. URL https://papers.neurips.cc/paper_files/paper/2024/hash/4e2c6423d724370b36c3a7612f25b78c-Abstract-Conference.html.

Johann Brehmer, Pim de Haan, Phillip Lippe, and Taco S. Cohen. Weakly supervised causal representation learning. In *Advances in Neural Information Processing Systems*, volume 35, 2022. URL https://papers.nips.cc/paper_files/paper/2022/hash/fa567e2b2c870f8f09a87b6e73370869-Abstract-Conference.html.

Diego Colombo and Marloes H. Maathuis. Order-independent constraint-based causal structure learning. *Journal of Machine Learning Research*, 15(116):3921–3962, 2014. URL https://www.jmlr.org/papers/v15/colombo14a.html.

Patrick Cooper and Alvaro Velasquez. Active causal experimentalist (ACE): Learning intervention strategies via direct preference optimization. arXiv:2602.02451, 2026. URL https://arxiv.org/abs/2602.02451v2. Version 2, June 2026; preprint.

Ziyi Ding, Xianxin Lai, Weiyu Chen, Xiao-Ping Zhang, and Jiayu Chen. CausalVAE as a plug-in for world models: Towards reliable counterfactual dynamics. In *Computer Vision – ECCV 2026*, volume 17017 of *Lecture Notes in Computer Science*, pp. 278–293. Springer, 2026. doi: 10.1007/978-3-032-37252-9_16. URL https://link.springer.com/chapter/10.1007/978-3-032-37252-9_16.

Alain Hauser and Peter Bühlmann. Characterization and greedy learning of interventional Markov equivalence classes of directed acyclic graphs. *Journal of Machine Learning Research*, 13:2409–2464, 2012. URL https://www.jmlr.org/papers/v13/hauser12a.html.

Alain Hauser and Peter Bühlmann. Two optimal strategies for active learning of causal models from interventional data. *International Journal of Approximate Reasoning*, 55(4):926–939, 2014.

Aneesh Komanduri, Yongkai Wu, Feng Chen, and Xintao Wu. Learning causally disentangled representations via the principle of independent causal mechanisms. In *Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence*, pp. 4308–4316, 2024. doi: 10.24963/ijcai.2024/476. URL https://www.ijcai.org/proceedings/2024/476.

Yunzhu Li, Antonio Torralba, Anima Anandkumar, Dieter Fox, and Animesh Garg. Causal discovery in physical systems from videos. In *Advances in Neural Information Processing Systems*, volume 33, 2020. URL https://proceedings.neurips.cc/paper_files/paper/2020/hash/6822951732be44edf818dc5a97d32ca6-Abstract.html.

Phillip Lippe, Sara Magliacane, Sindy Löwe, Yuki M Asano, Taco Cohen, and Stratis Gavves. CITRIS: Causal identifiability from temporal intervened sequences. In *Proceedings of the 39th International Conference on Machine Learning*, volume 162, pp. 13557–13603. PMLR, 2022. URL https://proceedings.mlr.press/v162/lippe22a.html.

Phillip Lippe, Sara Magliacane, Sindy Löwe, Yuki M Asano, Taco Cohen, and Efstratios Gavves. BISCUIT: Causal representation learning from binary interactions. In *Proceedings of the Thirty-Ninth Conference on Uncertainty in Artificial Intelligence*, volume 216, pp. 1263–1273. PMLR, 2023a. URL https://proceedings.mlr.press/v216/lippe23a.html.

Phillip Lippe, Sara Magliacane, Sindy Löwe, Yuki M. Asano, Taco Cohen, and Efstratios Gavves. Causal representation learning for instantaneous and temporal effects in interactive systems. In *International Conference on Learning Representations*, 2023b. URL https://arxiv.org/abs/2206.06169.

Disheng Liu, Yiran Qiao, Wuche Liu, Yiren Lu, Yunlai Zhou, Tuo Liang, Yu Yin, and Jing Ma. CAUSAL3D: A comprehensive benchmark for causal learning from visual data. *arXiv preprint arXiv:2503.04852*, 2025. URL https://arxiv.org/abs/2503.04852.

Christopher Meek. Causal inference and causal explanation with background knowledge. In *Proceedings of the Eleventh Conference on Uncertainty in Artificial Intelligence*, pp. 403–410, 1995. URL https://arxiv.org/abs/1302.4972.

Rafael Rodriguez-Sanchez, Cameron Allen, and George Konidaris. From pixels to factors: Learning independently controllable state variables for reinforcement learning. arXiv:2510.02484, 2025. URL https://arxiv.org/abs/2510.02484. Preprint.

Sorawit Saengkyongam, Elan Rosenfeld, Pradeep Ravikumar, Niklas Pfister, and Jonas Peters. Identifying representations for intervention extrapolation. In *International Conference on Learning Representations*, 2024. URL https://proceedings.iclr.cc/paper_files/paper/2024/hash/aa9508b2577e0d9c824da9e2e27fe9d6-Abstract-Conference.html.

Nino Scherrer, Olexa Bilaniuk, Yashas Annadani, Anirudh Goyal, Patrick Schwab, Bernhard Schölkopf, Michael C. Mozer, Yoshua Bengio, Stefan Bauer, and Nan Rosemary Ke. Learning neural causal models with active interventions. arXiv:2109.02429, 2021. URL https://arxiv.org/abs/2109.02429. Revised March 2022.

Bernhard Schölkopf, Francesco Locatello, Stefan Bauer, Nan Rosemary Ke, Nal Kalchbrenner, Anirudh Goyal, and Yoshua Bengio. Toward causal representation learning. *Proceedings of the IEEE*, 109(5):612–634, 2021. URL https://arxiv.org/abs/2102.11107.

Sumedh A Sontakke, Arash Mehrjou, Laurent Itti, and Bernhard Schölkopf. Causal curiosity: RL agents discovering self-supervised experiments for causal representation learning. In *Proceedings of the 38th International Conference on Machine Learning*, volume 139, pp. 9848–9858. PMLR, 2021. URL https://proceedings.mlr.press/v139/sontakke21a.html.

Valentin Thomas, Emmanuel Bengio, William Fedus, Jules Pondard, Philippe Beaudoin, Hugo Larochelle, Joelle Pineau, Doina Precup, and Yoshua Bengio. Disentangling the independently controllable factors of variation by interacting with the world. arXiv:1802.09484, 2018. URL https://arxiv.org/abs/1802.09484.

Panagiotis Tigas, Yashas Annadani, Andrew Jesson, Bernhard Schölkopf, Yarin Gal, and Stefan Bauer. Interventions, where and how? experimental design for causal models at scale. In *Advances in Neural Information Processing Systems*, volume 35, 2022. URL https://arxiv.org/abs/2203.02016.

Zirui Yan, Emre Acartürk, and Ali Tajer. Reward-oriented causal representation learning. In *Advances in Neural Information Processing Systems*, volume 38, 2025. doi: 10.52202/085713-1381. URL https://papers.neurips.cc/paper_files/paper/2025/hash/3b04bba0f95caacbd9aa9033e2c913c9-Abstract-Conference.html.

Mengyue Yang, Furui Liu, Zhitang Chen, Xinwei Shen, Jianye Hao, and Jun Wang. CausalVAE: Disentangled representation learning via neural structural causal models. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 9593–9602, 2021.

Zhiyu Zhao, Haoxuan Li, Haifeng Zhang, Jun Wang, Francesco Faccio, Jürgen Schmidhuber, and Mengyue Yang. Curious causality-seeking agents in open-ended worlds. In *Advances in Neural Information Processing Systems*, volume 38, 2025. doi: 10.52202/085713-5145. URL https://papers.neurips.cc/paper_files/paper/2025/hash/e21c92a1661709c3caf21fdd958bac99-Abstract-Conference.html.

A 实验协议、统计口径与场景

A.1 实验问题与协议索引

实验区分五个问题：

系统比较 表 1、3、4分别计图、总体状态均值和 RGB 误差，各方法使用自身表示及查询路径；物理 ILCM 的权限不同。

方向信息 附录 C.2与 C.1分别报告三种子等新增记录对照与八种子 MEC 实验。前者已有校准干预，并非完全被动流程与干预流程的比较。

校准作用 表 2固定每种子的 encoder、已学图、查询与 ID 后拟合 D'，按各自坐标重拟合机制，报告三种子均值与 SD；配对差见附录 D.4。普通更新另改变读出与 decoder。

图像解码 附录 E.1仅将 D 改为 D'，三种子配对中的因果状态与效应输出保持不变。

采集预算 附录 F.3在 $B = B_{\text{cal}} + B_{\text{graph}}$ 下比较策略，采用批量方向检查，报告全部三种子的实际调用数、恢复与预算耗尽。

所有模块、尺度和查询规则均在测试时冻结。附录 D.2使用同证据得到的各组冻结图，不重新采样学图；附录 D.3从同一采集轨迹在各自坐标中重新学图和拟合机制。两者均不替代正文固定图对照。共用输入和 decoder 不意味着机制参数相同；Gears 固定图组不检验图的重新发现。

比较资格与分母规则集中于附录 A.2，指标与分布见附录 A.6、A.8。Gears 负结果、仿射占优条件及预算耗尽仍按各自实验组解释。

A.2 比较范围与统计单位

系统比较采用所报告的统一数据与监督设置，本文方法使用学习型 T；附录 A.3区分系统比较、物理场景适配与各项机制对照。ICM-VAE 是给定图的生成参考，不参与图发现比较。物理 ILCM 的配对权限与预算不同，不参与统一排名：$n = 1$，四目标、两命令、32 情境，共 256/256 个查询。其他 MEC 基线诊断仅涉及所列 seed300 检查点（$n = 1$），不覆盖主表所有同名模型。

共同评价定义与比较权限。 任务比较采用所述输入与计分定义：反事实生成接收事实图片及目标/设定值，总体预测仅接收目标/设定值，后果误差排除直接设定目标。归一化使用训练数据，模型与查询规则在测试时冻结。图分数、状态 NMSE 和像素 MSE 对应不同结果，不合并统计。相同的数据与监督权限不要求原生架构相同；额外真图、配对数据或可训练模块对应单列参考，而非匹配组件消融。下述匹配对照比聚合系统排名更适合组件归因。等总预算的采集比较限于附录 F.3，不能仅凭任务主表误差推出等成本优势。

查询、阻断项与统计分母。 表 3与 4只计已执行查询，阻断项不填零、不赋任意惩罚。若各方法在不同样本上失败，相同任务定义不等于相同保留查询集合。表 1的比例计完成/计划运行，不是正确图恢复率、预测种子数或已执行/计划查询数。因此主表汇总描述条件误差，不估计端到端成功率或共同保留查询总体上的优势。表 A2将已知运行数与预测分母分开；补充组的计数和有效集合仅适用于本组，不从图表推断预测分母。

种子内汇总与种子间不确定性。 表 2各配置使用相同的 64 个事实情境、7 个目标与每目标每 split 两个命令，即每种子每 split 896 条 CF，种子 5、6、7 全部计入。每种子内对目标和命令等权汇总，再报告三种子误差的均值及样本 SD，而非把 2688 张图当作独立样本计算 SD。附录 D.4在相同种子上计算配对差，不能以两组 SD 相减作为配对 SD。无不确定性区间的任务主表单元格是点估计，其聚合权重和逐种子方差不能由均值反推，也不借用上述三种子的分母和 SD。表 A1中的独立物理对照汇总同样不用于估计配对校准收益。

配置与归因。 表 2的三种校准共用每种子的 encoder、数据、图与 D'（$n = 3$，每种子每 split 896 条 CF）；普通更新另训练读出与 decoder。“无图”构造随实验组定义，可能重建根节点模型，而非保持已拟合机制不变（附录 B.2）。图 5A 示意完整查询路径，B 展示无校准的物理条件均值对照；附录图 A4采用学习型校准与事实残差。decoder 收益和方向信息均不能单独归因于校准。

A.3 评测配置与统计范围

任务主表报告统一数据与监督协议下学习型 T 的结果。表 A1分别列出系统比较、物理场景适配与机制对照；各组的统计数量和配置分别解释。

表 A1: 主表与补充组的记录对应。已知分母只属于所列运行，不能按同名方法或相同舍入值迁移。

结果位置	配置与记录	查询、权限及对应范围
表 1、3、4的汇总单元格；下行除外	本文方法采用学习型 T，各方法按统一数据与监督协议比较；表内无区间的单元格报告点估计。	表 1下部是流程完成数，不是逐查询执行率。预测误差仅对已执行查询统计，不构成端到端成功率或共同查询总体上的优势估计。
表 4的物理 ILCM	`run_s42_v1`，种子 42；原生隐式机制与自身 decoder；按 ID 验证选择第 120 轮。	1280 训练对、256 验证对；32 情境 $\times$4 目标 $\times$2 命令，256/256 查询。与归档种子 42 的配对 GT 相同，但不证明主表其他汇总具有相同有效集合；权限和预算不同，见附录 A.9。
附录 C.4的 MEC 机制对照	种子 300/301，学习型 T；冻结表征、校准映射与图机制；2400 张独立 ID 图片训练共享 decoder。	PnP/Gears 为 2/2 有效种子，Balance 为 1/2；每有效种子分别 384/384/320 条 CF。命令范围与 2048 样本后果评价只属于此组。
物理无校准对照（汇总）	不作数值校准；整图像素 MSE 汇总为 0.930（$\times 10^{-3}$）。	与下行配对对照分开报告；不沿用其种子数、标准差、查询数或训练预算，不用于估计相对主表学习型 T 的配对校准收益。
附录 A.9的条件均值传播配对对照	不作数值校准，后代不加回事实残差；共同完成种子 42、314。	每种子 256 条共同查询；本文方法完成 2/3、CausalVAE 完成 3/3，后者使用更多概念标签。分项误差见附录 A.9。

逐基准协议汇总。 表 A2将任务主表信息与下述有独立记录的对照分开列出。共同输入、指标、冻结和排除规则见附录 A.2；这些规则不决定各场景的数值采样范围或实际执行查询集合。

表 A2: 任务主表的协议索引。运行完成数复用表 1，不是正确图恢复率或预测查询成功率。预测种子数 n、已执行查询 Q 和含校准采集总量 B 是不同字段。

基准	任务变量	操作与测试分组	完成/计划运行	预测 n, Q, B
Domino SCM	7 个连续状态：推杆、四块骨牌、铃、灯	单状态设定；所报告的 ID/幅值组	8/8	—
物理 Domino	4 个二值终态倒伏事件	固定直立/倾斜后释放；测试集 A/B	7/8	—*
PnP	6 个 SCM 变量	单状态设定；所报告的 ID/幅值组	8/8	—
Balance	5 个 SCM 变量	单状态设定；所报告的 ID/幅值组	7/8	—
Gears	6 个 SCM 变量	单状态设定；所报告的 ID/幅值组	8/8	—
CAUSAL3D Spring	计分状态向量—	具体目标/范围—；测试集 A/B	8/8	—
CAUSAL3D Seesaw	计分状态向量—	具体目标/范围—；测试集 A/B	6/8	—
CausalWorld	具体任务与计分状态向量—	具体目标/范围—；测试集 A/B	7/8	—

长横线表示聚合记录未给出该字段，不表示零或运行失败。测试分组标签不提供精确训练/测试生成器与数值范围，A/B 本身不定义 OOD 变化轴。* 物理 ILCM 是有独立记录的参考：种子 42、1280 对训练图、256 对验证图、256/256 条 CF。其 3072 次配对生成图像调用的权限和计量不同，不是匹配的 $B_{\text{cal}} + B_{\text{graph}}$ 总量，不能填写到其他方法的单元格。

有独立记录的对照协议。 下列记录仅属于所指明的对照，不替代任务主表协议。

- **匹配采集的 Domino 对照（附录 D.3）**。七节点场景覆盖全部目标，使用种子 5/6/7、6000 条观测和 896 条校准记录。新增学图记录分别为 1800/3600/3600，因此种子 5 的 B 为 $896 + 1800$，种子 6/7 为 $896 + 3600$。独立 ID 情境的命令为 $\mu_j^s \pm 0.75\sigma_j^s$，幅值测试为 $\mu_j^s \pm 2\sigma_j^s$，其中均值和尺度来自训练标签。每种子在两 split 合计执行 1792 条 CF。其图与 decoder 条件仍与表 2区分。
- **物理配对对照（附录 A.9）**。四个二值事件以固定/释放命令查询。训练使用 512 张带标签图片、128 张 ID 验证图片和 512 张独立观测图片。种子 42/314 可执行，2718 阻断，$n = 2/3$；32 个留出初态形成每完成种子 256 条 CF。已知学图采集分量为 256 条，不据此推断含校准总量。这些计数不描述表 A1中的独立物理对照汇总。
- **MEC 机制对照（附录 C.4）**。PnP 变量为臂位/抓取开度标记、物体 x/高度、目标 x 和灯；Balance 为负载差、倾角、球 x、收集箱 x 和灯；Gears 为驱动、两级齿轮角、指针、目标和灯（附录 A.7）。PnP 标记不代表固定在 HOME 的机械臂的实时姿态。各场景全部目标均被查询，命令取训练映射的物理原点 $\pm 0.75/\pm 2$ 个尺度单位。共享 decoder 用 2400 张独立 ID 图训练；32 个 CF 情境与每目标两个命令，分别形成 PnP/Balance/Gears 每可执行种子 384/320/384 条查询。种子 300/301 在 PnP/Gears 均可执行，Balance 仅 300 可执行。总体测试每命令使用 2048 个模型和模拟器样本；这些对照的完整 encoder 训练分布和含校准总量未给出。

上述受控 MEC 节点定义、Spring/Seesaw 原图适配器及 CausalWorld Pushing 示例均不替代任务主表计分列的定义。

配置区分与解释范围。 PnP、Balance 与 Gears 的 MEC 机制对照采用学习型 T，其细分统计见附录 G.1；刚体条件均值对照不作数值校准，不用于估计校准增益。相同数值不转移不同实验组的种子分母或数据权限。跨环境主表按聚合指标报告，不提供完整的逐运行配置和逐查询记录，因此不据其点估计推断统计显著性或共同查询总体上的优势。Spring、Seesaw 的计分节点、单位与真图，CausalWorld 的具体任务与状态，以及各列的训练/测试生成分布，

不能由其他诊断组或图 4的场景示意代替。表 3的连续列保留所报告的 ID/幅值标签，其余列作 A/B 测试；各具名对照的分布与查询见附录 A.8。

A.4 因果术语速查

图与独立性。 在 $G = (V, E)$ 中，$i \to j$ 表示 j 的结构方程直接依赖 i；E 是边集，不是编码器 E_θ。DAG 不含有向环。父集合为 $\mathrm{Pa}_G(j) = \{i : i \to j \in E\}$，后代 $\mathrm{De}_G(i)$ 由有向路径可达且不含 i。因此 $1 \to 2 \to 3$ 可传播作用而不要求 $1 \to 3$，响应相关也不等于直接边。

对互不相交索引集 A, B, C，$s_A \perp\!\!\!\perp s_B \mid s_C$ 表示条件独立。Markov 条件将图中的 d-分离对应到分布独立，忠实性排除精确抵消产生的额外独立 (Colombo & Maathuis, 2014)；零相关不等于一般独立。去掉箭头得到骨架，PDAG 可含未定向边，CPDAG 表示观测等价类 (Hauser & Bühlmann, 2012)。有限样本输出可能错误或不相容，任意补全不是识别。

干预与查询。 $\mathrm{do}(s_j = u)$ 替换目标机制；条件化 $P(s_k \mid s_j = u)$ 只筛选观测样本，保留原有原因。本文 u 是已达到并核验的状态，而非未经验证的命令 u_{cmd}；物理动作能否实现该操作由任务决定。校准 T 修改视觉映射，不改变环境。

因果充分性、外生扰动独立和无选择偏差是环境假设，不由编码自动满足。拟合残差 η_j 不是已观测的 ϵ_j。事实图片查询保持估计情境，总体查询重新采样；单帧隐藏信息可能妨碍个体反事实的唯一识别，配对 GT 提供评价而非识别保证。完整模型记法与查询公式见附录 A.5、B.4。

标签确定节点身份，校准调整数值读数；训练单位、$\alpha_j(u)$、$q_j(u)$ 和逆映射冻结。幅值变化、新机制与新视角分别定义，静态图求值不是时序动力学。预算 $B = B_{\mathrm{cal}} + B_{\mathrm{graph}}$ 计返回记录，批次和优化步数另计；计分定义见附录 A.6。

A.5 模型与拟合残差的完整记法

真实 SCM 包含正文定义的图、结构方程与外生分布：

$$\mathcal{S}^\star = (G^\star, \{f_j^\star\}_{j=1}^K, P_\epsilon), \qquad G^\star = (V, \mathcal{E}^\star).$$

学习对象可写为

$$\widehat{\mathcal{M}} = \big(E_\theta, T_{\widehat{\phi}}, \widehat{G}, \{\widehat{f}_j\}_{j=1}^K, D_\psi\big), \qquad h_j = \widehat{f}_j(h_{\mathrm{Pa}_{\widehat{G}}(j)}) + \eta_j.$$

E_θ, D_ψ 分别为编码器和解码器，$T_{\widehat{\phi}}$ 为拟合的校准映射，$\widehat{G}$ 为估计图，$\widehat{f}_j$ 为局部预测机制。η_j 为拟合残差，而非已恢复的真实外生噪声。观测、干预和事实图像经同一冻结接口进入该模型；其数值近似与查询流程分别见正文方法及附录 B.4。

A.6 评价符号与场景展示来源

图指标为 $\mathrm{SHD} = N_{\mathrm{add}} + N_{\mathrm{del}} + N_{\mathrm{rev}}$，其中加边、删边和反向操作将估计图改为真图，反向计一次；$\mathrm{AUPRC} = \int_0^1 \mathrm{Prec}(\rho)\,\mathrm{d}\rho$ 中 ρ 为召回率、Prec 为精确率。AUPRC 描述边分数排序，与表 1的流程完成比例不同。

MEC 部分图对照对每个无序对 $i < j$ 最多计一次错误：缺失/多余邻接、反向、真边未定向或双向冲突。两图都有邻接时，仅正确单向箭头计零，总误差上界为 $K(K-1)/2$；错误方向和未解决边另报。SHD 不是图有效性或执行门槛，系统表计分范围见附录 G.1。响应相关既不是总效应估计，也不将所有受影响后代连成边，判据见附录 B.1。

状态均值、图像与归一化。 表 3比较操作 $a = (j, u)$ 下各非目标节点 $k \neq j$ 的模型均值 $\widehat{\mu}_k(j, u)$ 与模拟器干预均值 $\mu_k(j, u)$，先按训练确定的逐节点尺度归一化，再平方计误差。目标被排除；低误差评价预测，不唯一确定真实机制。这不同于事实条件 $\widehat{x}^{\mathrm{cf}}(x, a)$ 和下一帧预测，场景分布范围见附录 A.8。

比值 $r = E_{\mathrm{A}}/E_{\mathrm{B}}$ 由已舍入汇总相除，不是逐运行比值平均或显著性检验。在 $E_{\mathrm{B}} \geq E_{\mathrm{A}} > 0$ 时，较大 r 对应较小相对增长，但也可能源于第一组误差更差，须结合绝对误差解读；零分母不给有限比值。只有已定义相应偏移时，A/B 才表示 ID/幅值变化。

符号与固定量。 $q_\theta(z \mid x)$ 为编码后验，$q_j(u)$ 为模型节点设定；U_t 是未定向边集，$\mathcal{U}_j$ 是可行值域，$\mathcal{A}_t \subseteq \mathcal{J}$ 是可选目标。系数向量 a_j 不同于操作 a。训练标签确定 μ_j^s, σ_j^s，冻结 T 后的训练观测确定 μ_j^c, σ_j^c；带上标的 μ_j^s, μ_j^c 是固定标准化统计量，区别于随操作 (j, u) 变化的干预均值 $\mu_k(j, u)$。标准差稳定项为 10^{-8}，不在测试集重估。拟合参数 $\widehat{\phi}$ 与残差 η_j 不是真实环境参数/噪声。式 (4)只平均允许的训练记录，λ 权衡目标误差与观测保持。

A.7 环境场景与生成图的来源

图 4上排三类 MEC 取固定采样种子 20260924 的首个观测状态，以原渲染器重渲染，不作图像增强或模型预测。PnP 采用 512×768、Balance/Gears 采用 512×512 展示；主实验输入尺寸与样本不变。因果边直接读取各环境的邻接矩阵，机械臂保持统计帧的固定 HOME 姿态。图的重排只改变节点位置，不增删边。此图展示受控 SCM 与渲染接口，不表示这些关系由机器人接触动力学辨识得到。

PnP-MEC
: arm_x → obj_x ← grasp，grasp → obj_lift，obj_x → led ← target_x。图中 arm x、grasp 分别对应持久化的指令位置与抓取开度标记，不是固定 HOME 机械臂的实时末端位置；object x 与 lift 对应对象水平/竖直状态，target x 为目标位置，lamp 为指示灯状态。

Balance-MEC
: load_delta → tilt → ball_x → led ← bin_x，对应负载差、横梁倾角、球位置、指示灯状态与收集槽位置。

Gears-MEC
: drive → g1 → g2 → ptr → led ← target，对应驱动量、两级齿轮角状态、指针位置、指示灯状态与目标盘位置。

这三张图对应独立受控 MEC 实现，其协议和查询结果见附录 C.1与 C.4。主表其他场景使用各自的节点集和生成关系，图中的 SCM 不代表其他环境的真图。

下排 Spring 与 Seesaw 分别取官方数据已固定测试清单的首个样本 Spring:1004 与 Seesaw:1001，直接使用原始 256×256 PNG，未按模型误差或视觉质量挑选。CausalWorld 使用官方 `causal-world==1.2` 的原生 Pushing 任务，固定种子 20260925 并仅执行一次默认 reset；沿用官方相机与几何，以 PyBullet DIRECT 及 TinyRenderer 在 CPU 上渲染 320×240 预览，无动作搜索。这三幅图仅展示环境外观；其中 CausalWorld 预览不声称与主表的具体任务配置绑定，均不是 GT 反事实或模型预测。

A.8 逐场景测试分布

ID/OOD 描述训练与测试生成分布的关系，不由分数决定。训练生成器的独立情境是 ID；命令、初态、外观与机制变化构成不同偏移，模型、归一化和评价种子冻结。以下范围属于各自诊断组，不对应所有汇总列。

Domino-SCM
: 独立像素基座对照用训练锚点均值 ± 0.75 标准差作 ID、± 2 作幅值测试；另一个协议使用 $\pm 1.15 / \pm 1.75$。高斯训练命令有全支持，这些是幅值分布变化，不是严格支持外推。

其他 MEC
: PnP/Balance/Gears 独立基线比较采用训练概念均值 ± 0.75 标准差（ID）与 ± 2（幅值变化），不能据此定义每个主表运行。

物理多米诺
: 四个末态事件为二值，命令 0 固定直立，1 倾斜后释放。相同初态生成器的留出情境是配对 ID 测试；二值命令本身不定义幅值 OOD。

Spring、Seesaw、CausalWorld
: 表 3的 A/B 是两组测试数据，不是方法或监督组。分数不能确定幅值、初态、外观或机制偏移；其他 CausalWorld 任务的协议不能提供本列配置，也不证明跨域鲁棒性。

† 列是所报告的条件 A/B 汇总，未确定 OOD 类型或共同的保留查询总体；连续列报告标签的范围见附录 A.3。定义具体偏移还需实际训练/测试命令或情境分布及变化维度，不能从其他组补入缺失范围。

A.9 实验设置与完整分项结果

本附录给出恒等校准对照及刚体查询的训练数据、模型选择、样本分母与分项误差。各配置分别采用以下训练与查询协议。

统一坐标设置。 本附录的无校准对照直接使用编码器读数，与主表的学习型校准配置分开报告。SCM 对照共享每种子冻结的视觉模型与数据池；刚体对照以四个倾倒事件为表示，按条件均值传播干预后果。这些结果用于分析图传播，不用于估计非线性校准的增益。

SCM 多米诺。 七个节点为推杆、四块骨牌、铃和灯，图像由结构方程驱动的运动学渲染生成。RGB64 与 RGB128 各使用 10 个训练种子、6000 条观测训练记录，视觉模型训练 350 轮。后续接口收集 14 批、每批 64 条预定 ID 干预记录；同一记录池用于对应坐标下的机制拟合。每种子每目标 64 个同噪声配对反事实查询。RGB64 有 8 个可执行下游种子，其中 1 个图完整但错误；RGB128 有 9 个。其余种子保留未定向状态。均值与标准差按有效种子统计，两种分辨率的计划分母均为 10，细分结果见附录 G.1。

刚体条件均值传播配对对照。 以下设置和分项统计对应种子 42、314、2718 的运行；它们与表 A1物理无校准汇总及主表学习型校准汇总分开报告，不为后两者提供种子分母、标准差或预算。四个节点表示各骨牌最终是否倾倒；偏离竖直至少 10° 记为 1。$F_j = 0$ 通过固定直立实现，$F_j = 1$ 通过初始倾斜后释放实现，生成器检查目标的实际结算值。机械臂、铃灯为固定场景部件。事实与反事实共享物理初态与其他参数，输入为 RGB128 图像及干预命令。32 个测试初态、四目标、两设定值形成 256 个配对查询。这组评价的直接对象是固定/释放命令下的同初态重放。目标达值检查不单独证明末态 SCM 的模块性：物理动作仍可能经未被二值事件表示的路径影响其他变量。因此它不作为式 (2)的理想硬干预假设已经在物理系统中成立的证据。本文方法使用 512 张带概念标签的训练图、128 张 ID 验证图，以及 512 张独立观测图学习骨架。两个完整运行各执行两轮、每轮 128 条干预记录。视觉模型训练 100 轮，随后冻结编码器，以同一训练图片作 100 轮解码器后拟合（用冻结编码器的后验均值重建训练图片），候选仅按 ID 验证选择。三个预定种子为 42、314、2718，最后一个因部分图歧义停止下游查询。

CausalVAE。 保持作者四概念、每概念四维的模型、训练损失、DAG 模块及潜变量干预路径，适配 RGB 分辨率和标签尺度；图从零初始化。原生干预算子对前两个和后两个概念槽位采用不同分支，本表对应这一固定实现的任务适配。推断采用确定性潜变量均值，输入仅为事实图片和允许的命令。1280 图组包含 512 张锚定图、512 张观测图及 256 张干预图，且向该模型提供全部概念标签。因此，它比本文方法使用更多标签；两者在相同 32 初态查询集上评分。本组同时报告原始解码器和额外 ID 重拟合解码器，反事实对照采用结果更强的原始解码器。

表 A3: 刚体多米诺配对对照的分项误差，单位 10^{-3}。整图列为共同完成种子 42、314 的均值 ± 样本标准差；不对应表 A1的物理无校准汇总或主表学习型校准汇总。

配置	整图 MSE	保持直立	令其倾倒
本文方法（条件均值传播）	0.880 ± 0.016	1.282	0.478
事实残差传播对照	0.924 ± 0.026	0.997	0.850
仅目标潜变量编辑	1.373 ± 0.001	1.064	1.682
CausalVAE，512 图，原始解码器	1.617 ± 0.153	1.305	1.929
CausalVAE，1280 图，原始解码器	1.287 ± 0.039	1.051	1.523
CausalVAE，512 图，ID 重拟合	1.946 ± 0.077	1.640	2.252
CausalVAE，1280 图，ID 重拟合	2.272 ± 0.071	1.764	2.780

解读分项差异。 条件均值传播指后代直接使用局部回归均值，不加回事实残差。其优势主要来自连锁倒伏。保持直立的查询中，CausalVAE 原始解码器优于该分支；保留事实残差则有所缓解。四个二值事件可能丢失决定某次倒伏的隐藏初始触发原因，因此像素误差和个体后果保持分别报告。解码器重拟合改善 ID 重构却提高 CausalVAE 的反事实误差，说明两类指标衡量不同能力。

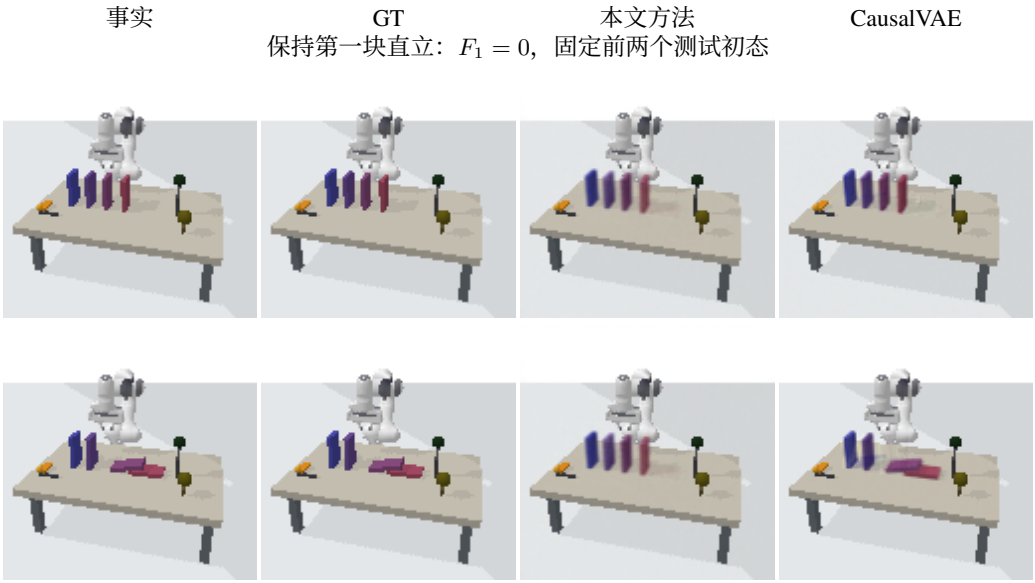


图 A1: 与正文相同的种子 42 和事实初态，改为 $F_1 = 0$。第二行显示条件均值传播改变了事实中独立倒伏的后代。预测像素保持原始输出。

干预分布评价。 ID 命令为 ± 1.15，幅度变化命令为 ± 1.75；模型与 GT 分别生成样本，比较分布均值图片和冻结原编码器坐标均值。原坐标误差是视觉读出的误差，不是独立物理状态误差。下游失败种子不以零误差填补。附录 G.1中的两种分辨率使用不同的有效种子集合，不填入正文的 NMSE 总表。

图后端对照的输入。 PC 接收共享编码器的观测矩阵 $Z_{\text{obs}} \in \mathbb{R}^{N \times K}$；干预图学习器另接收对应记录及目标掩码 $M \in \{0,1\}^{N \times K}$。$N$ 为记录数，K 为节点数；M 的元素为 1 时表示对应节点在该记录中被直接干预。相同编码器、归一化统计和数据权限使差异定位到图学习后端。该比较与 CausalVAE 从图片训练自身表示的端到端比较分开解释。

图 5B 的 ILCM 物理场景适配。 ILCM 使用与图 5B 配对 GT 相同的物理环境及 RGB128 渲染设置，单独训练四维连续潜变量模型。其官方图像网络不直接支持 128 分辨率，因此在 64 分支的 encoder 与 decoder 各增加一级原生残差缩放层；隐式机制、Gaussian 接口及训练目标保持原实现。训练种子为 42，使用 1280 对训练图片和 256 对独立 ID 验证图片；每对共享初始情境，保留操作后未出现变化的配对。训练采用 20 轮预训练及 100 轮机制训练，Adam 学习率 10^{-4}、批大小 32，以完整机制阶段的 ID 验证目标选择检查点。训练不读取干预目标标签或真图；训练后仅用训练集事件标签匹配潜变量排列，并以两个事件类别的潜变量均值确定命令端点。

查询先从事实图编码 noise 坐标，利用原生条件 solution 函数将目标值转换为目标 noise，保持其余 noise 不变，再由 ILCM 自身 decoder 生成图片。生成不调用本文的机制或 decoder，也不读取 GT 作为输入。图 5B 固定使用种子 42、情境 59000000（测试初态索引 0）及第一块倾倒命令，不按图片质量挑选案例。配对数据产生 3072 次仿真调用，与其余模型的训练预算不同；该运行的 256 查询均值见主表对应单元格。四个二值倾倒事件及物理固定／释放命令不完全满足连续 ILCM 的识别假设，因此代数干预检查不构成因果语义识别证明。

该适配的输出较模糊且命令响应很弱：在 32 个固定测试情境中，将第一块的命令从 0 改为 1，ILCM 预测图片的 RGB 平均绝对变化为 2.28×10^{-5}，配对物理 GT 的变化为 9.91×10^{-3}。该配置不足以构成充分训练的反事实基线；图 5B 展示其真实输出，结论限定于这一单种子适配，不代表 ILCM 方法的一般能力。表示压缩、优化收敛和物理任务适配的影响尚不能由此区分。

B 算法、查询实现与机制近似

B.1 完整流程与执行条件

算法 1 拟合视觉模型与校准，冻结接口后采集图证据，再拟合机制。主流程用式 (4)学习 T，不作数值校准的情形单列为对照。推断参数均冻结，预算计环境返回记录。

算法 1：视觉表征校准与主动图发现

输入： 训练图像与概念标签 $\mathcal{D}_{\text{obs}}$；可干预目标 $\mathcal{J}$ 及已冻结的 ID 命令分布；环境调用预算 $B = B_{\text{cal}} + B_{\text{graph}}$；训练、校准、独立性检验和定向配置。

输出： 上游输出冻结表示 h、带未定向标记的估计图 $\widehat{G}$ 及定向证据；满足执行门槛时，下游拟合共享局部机制，提供反事实解码和基于 $\hat{f}$ 的后果计算接口。

1. 用训练图像与概念标签学习 E_θ, D_ψ，随后冻结；不读取测试状态、真实图或测试结果。
2. 按预设轮转顺序调用环境，累计 B_{cal} 条 (j, u, x^{int}) 记录。每批 n 条记录计 n 次调用，重复目标照常计数；累计回放已有记录的优化步骤不重复计环境次数。
3. 用式 (4)拟合 T_ϕ。在预定轮次结束后冻结 T，仅以训练观测计算 μ^c, σ^c，建立式 (5)的统一接口 h。无校准对照直接保留编码器读数并单列。
4. 在 $h(\mathcal{D}_{\text{obs}})$ 上执行 PC 类邻接搜索，记录分离集、碰撞结构及 Meek 传播，得到初始部分图 $\widehat{G}_0$。若图结构不一致，返回失败记录，不以真实图替换。
5. 初始化图发现调用计数 $b = 0$、干预记录集为空。保留 $\widehat{G}_0$ 的观测定向及其初始未定向邻接集合。
6. 当仍有未定向边且 $b < B_{\text{graph}}$ 时：
   (a) 按式 (13)选择覆盖当前未定向边的目标；RGB 逐项更新组采用最小节点编号破同分及每目标六块上限，具体规则见附录 B.3。不得读取真图。
   (b) 从冻结 ID 分布抽取命令并执行环境操作，获取结算图像；末批不得超过剩余预算。获得 n 条记录后令 $b \leftarrow b + n$。
   (c) 将新图像送入同一冻结 h；把标记每条记录哪个节点被直接操作的单目标干预掩码与编码响应追加到累积证据中。编码器、校准及归一化统计量不在线更新。
   (d) 从 $\widehat{G}_0$ 及累积证据重建当前部分图。仅检验初始 CPDAG 中的未定向候选边，不改写观测必然方向；按本附录的响应决策表提出候选方向。
   (e) 逐项在图副本上试加候选方向；有反向冲突、环或不一致 DAG 扩展时拒绝。检查通过后执行 Meek 方向传播，直至没有新方向可推出，再提交该项更新；记录接受、拒绝及传播的原因和来源。
7. 在无剩余未定向边、目标规则不再允许新查询或预算用尽时停止。返回最终部分图和全部未解决方向，不按节点编号补边。
8. 仅当图有效、未定向边数为零且无环时，拟合正文所述局部机制。否则返回下游阻断状态；不得把可执行 DAG 补全作为主方法已识别的图。

完整 DAG 门槛与阻断单位。 本入口的“充分定向”严格指全图未定向边数为零，不是仅查询所需子图已定向。附录 D.3先对每个种子–配置检查图有效且无未定向边，再由机制构造的拓扑排序拒绝环；未通过者不构造预测器，该配置的全部计划 CF 和总体查询均阻断，不从部分图挽救某些目标。因此这是种子–配置级门槛，不是逐查询可回答性判定；种子执行比例不能替代查询级可回答率。附录 C.3的预定一致扩展对照独立于本门槛。

训练结束后如何使用模型。 事实图像查询保持估计残差并按式 (7)解码；仅命令的后果查询按式 (18)重采训练根节点与残差。两者使用同一拟合 $\hat{f}$，不读取测试真状态（附录 B.4）。静态图求值不是时间演化，时序预测还需轨迹接口、跨时间图及转移机制。

实现范围与失败报告。 随机单目标记录的边际响应相关在 $n \le 30$ 时不可用。规则假设干预有效、候选邻接可靠；单侧弱证据可能反向定向，也不能普遍区分直接和祖先作用。固定顺序的逐项闭包可复现，但不保证顺序无关。阈值、骨架错误、视觉混合和有限样本均可能误定向，Meek 传播不能修正统计上错误的前提。

直接响应判据。 令 $c_i = |\widehat{\mathrm{Corr}}(h_i, h_j; \mathcal{I}_i)|$、$c_j$ 对称，每侧须有至少 31 条单目标二值掩码记录才可用。取 $\tau = 0.15, \delta = 0.05$，决策如下；表中候选方向须通过图一致性检查后才被接受。

证据	条件	候选
双侧可用	$c_i > \tau,\ c_j < \tau,\ c_i - c_j \ge \delta$	$i \to j$
双侧可用	上行交换 i, j	$j \to i$
双侧可用	其余（含两侧同强/同弱或差距不足）	未定向
仅 i 侧	$\lvert c_i - \tau \rvert < \delta$	未定向
仅 i 侧	不在上述区间且 $c_i > \tau$	$i \to j$
仅 i 侧	不在上述区间且 $c_i \le \tau$	$j \to i$
仅 j 侧	对称处理	对称
均缺失	无可用响应分数	未定向

实现将常量变量导致的非数相关值记为 0，而不是自动弃权；仅有这一侧时可能触发弱证据反向规则。因此，图结构的一致性检查不能保证统计定向正确。

校准的具体参数化与求逆。 七节点非线性校准固定 $L = 5$ 及 $\kappa = (-2, -1, 0, 1, 2)$，训练参数化为 $g_j = 1 + 0.25\tanh(\xi_j)$、$w_{jl} = 0.1\tanh(\omega_{jl})$，偏置 b_j 不受限。权重可正可负；上述范围使导数下界至少为 0.25, 共 49 个可学习标量。查询加载器检查 $g_j > \sum_l |w_{jl}|$。若权重全零, 用 $(y - b_j)/g_j$ 解析求逆;否则令 $W_j = \sum_l |w_{jl}|$,在 $[(y - b_j - W_j)/g_j - 10^{-6}, (y - b_j + W_j)/g_j + 10^{-6}]$ 内逐元素固定二分 60 次。训练观测上的往返误差门槛为 10^{-8}，不是对所有外推输入的全局数值精度保证。充分拟合仿射对照另用正斜率下界 10^{-6} 且无上界的加权最小二乘，与有界仿射对照的参数范围不同。

预算及日志。 预算单位是环境调用返回的独立记录数，不是优化步数或采集轮数。编码器训练使用的观测样本量与训练成本单列；校准和图发现合计不得超过 B。实现日志至少保存样本种子、命令与执行值、阶段、累计调用数、图前后状态、效应分数、拒绝原因及冻结参数/代码/数据哈希。

B.2 置信定向后端与空图查询算子

本节依据冻结判据、留出运行记录和查询实现, 补充两个特定对照的执行规则: Domino-MEC 八种子置信定向，以及附录 C.4的三场景空图对照。它们不自动适用于其他同名汇总单元格。

响应统计与重采样。 对初始观测 CPDAG 的未定向邻接 $i - j$，仅保留掩码中恰有一个目标的记录。分别在干预 i、j 的记录上计算无量纲绝对 Pearson 相关 $\widehat{d}_i = |\widehat{\mathrm{Corr}}(z_i, z_j \mid \mathrm{do}(i))|$ 和 $\widehat{d}_j = |\widehat{\mathrm{Corr}}(z_i, z_j \mid \mathrm{do}(j))|$。每侧至少 200 条记录才可用；在该侧对整行有放回重采样 2000 次，每次重新中心化并计算相关，得到 $D_i^{(b)}$、$D_j^{(b)}$。区间 $[L_i, U_i]$ 和 $[L_j, U_j]$ 取 0.005 与 0.995 分位数（线性插值）。两侧使用独立的确定性随机流；两侧均可用时，令 $\Delta^{(b)} = D_i^{(b)} - D_j^{(b)}$，以同样分位数形成 $[L_\Delta, U_\Delta]$，不是对跨干预配对个体作差。

非有限编码被拒绝，不足 200 条视为缺侧。重采样相关的分母不超过 10^{-12}、点估计分母小于 10^{-12} 或相关值非有限时，相应统计量置 0。常量输入不能单独触发强信号定向，但两侧规则中的弱侧仍可能为常量；这些门槛不证明真实因果方向。

校准噪声上界与冻结选择。 对每条两侧均可用的校准边，选取点相关较小一侧（相等时选索引 i 侧），将其区间上端加入该干预目标的多重集 $\mathcal{V}_k$；令 $\mathcal{V} = \bigcup_k \mathcal{V}_k$。目标噪声上界为

$$b_k = \min\left\{1,\ 0.03 + \begin{cases} \max\{\max \mathcal{V}_k, Q_{0.95}(\mathcal{V})\}, & |\mathcal{V}_k| \ge 4, \\ \max \mathcal{V}, & |\mathcal{V}_k| < 4. \end{cases}\right\}. \tag{8}$$

其中 Q_p 为采用线性插值的经验 p 分位数。因此 0.03 是对数据所得上界的附加间隔，不是直接比较相关的零效应阈值。按本文从 1 开始的节点编号，所用冻结值为

$$\begin{aligned} b_1 = b_6 &= 0.32561556156709537, \\ b_5 &= 0.32477945538327324, \\ b_2 = b_3 = b_4 = b_7 &= 0.3211601465259132. \end{aligned} \tag{9}$$

上界拟合本身不读取图真值；若 $\mathcal{V}$ 为空则校准报错。判据选择在种子 10–17 上逐种子留一，先封存预测，再用*校准集真图*筛去新增错箭头或无效图的候选；其余候选依次最大化完整图数、最大化正确边数、最小化未决边数，并按固定优先级破同分，再以全部校准记录拟合上界。四个预定候选的（置信度、附加间隔、信号超额、方向对比）为 $(0.99, 0.03, 0.10, 0.15)$、$(0.95, 0.03, 0.10, 0.15)$、$(0.95, 0.02, 0.05, 0.10)$ 和 $(0.90, 0.02, 0.05, 0.10)$，最终冻结第一组；若无候选通过，安全模式全部弃权。留出种子 20–27 的推断不读取真图。这里的统计判据校准与数值映射 T 的锚点校准不是同一程序。

方向判定与提交。 仅 i 侧可用时，$L_i > b_i + 0.10$ 才提出 $i \to j$；仅 j 侧可用时对称处理。弱单侧证据不提出反向边。两侧均可用时，规则为

$$\begin{aligned} i \to j: &\quad \widehat{d}_i > \widehat{d}_j, \quad L_i > b_i + 0.10, \quad U_j \le b_j, \quad L_\Delta > 0.15; \\ j \to i: &\quad \widehat{d}_j > \widehat{d}_i, \quad L_j > b_j + 0.10, \quad U_i \le b_i, \quad U_\Delta < -0.15. \end{aligned} \tag{10}$$

无可用侧、点估计相等或相应条件未全部满足时保留未定向；初始图无效时不提出定向。每轮从冻结初始 CPDAG 和累计记录重新计算，按未定向边列表*顺序提交*：候选边须保持无环，随后 Meek 闭包须通过一致扩展检查，才提交该边及传播结果；失败则放弃该次更新，跳过已被闭包定向的边。观测强制定向不可覆盖。0.99 是单项区间的名义置信度，不是整图正确概率。

固定阈值替换对照复用留出种子、冻结编码器、初始 CPDAG、按目标和采样块索引缓存的数据及采样预算设置，改用 $\tau = 0.15, \delta = 0.05$ 的原定向规则。不同后端可改变后续选靶，因此共享缓存不等于实际动作序列相同；8/8 与 4/8 比较的是对应终态完整恢复数，不是等动作路径比较。

该留出组每块 1800 条、最多六块，并设置每目标六块上限；达到有效且无未定向边的状态后不再采集，未完成者保留终态。这里的运行器只评价图，不构造下游查询预测器，故 8/8 完整图恢复不能当作查询可执行分母。

空图总体算子及事实条件分支。 本段对应附录 C.4中采用学习型 T 的 MEC 机制对照。以 w 记该组冻结视觉接口输出的机制坐标，以 $v_j(u)$ 记其训练单位转换后的命令。空图模型用*相同编码记录与干预掩码重新构建*，将邻接矩阵置零，所有节点均成为根节点。每个节点保存自身观测边际经验分布 $\widehat{P}_k^{\text{obs}}$；只有观测池为空时才退回未干预该节点的记录。它不保留原父系数或残差池，也不拟合根节点截距回归。

命令式总体查询对各非目标节点独立有放回采样，并钳制目标：

$$\widehat{P}_\varnothing(w \mid j, u) = \delta_{v_j(u)}(w_j) \prod_{k \neq j} \widehat{P}_k^{\text{obs}}(w_k). \tag{11}$$

原非根节点因此使用观测边际池，而非原拟合残差；也不是整行重采样以保留观测联合依赖。两方法接收相同命令和 GT 均值，每次各生成 2048 个模型样本，转换回协议单位后平均。每个命令为两方法重新初始化同一种子随机流，但图的拓扑遍历顺序不同，不能视为逐坐标噪声配对。

事实图像分支不采样这些池：复制事实向量 w^{fact}，仅令 $w_j = v_j(u)$，其余坐标不变，再送入共享解码器。该空图对象没有后代，因此与总体查询的边际乘积算子不同。另一个保留已拟合机制、仅关闭后代更新的模块消融应单独解释；相同的目标编辑输出不能确定总体预测器或实验组也相同。以上实现绑定于 PnP/Gears 各 2/2、Balance 1/2 的有效诊断种子，Balance 另一种子因未定向结构被两方法共同排除；不据此补全其他主表汇总的算子或查询分母。

B.3 视觉学习、覆盖选靶与局部机制的具体形式

本节给出视觉模型目标、覆盖式选靶和线性机制的具体公式，补充正文的校准与查询流程。

节点对齐的变分自编码器。 编码器 E_θ 估计与目标状态对应的潜变量 z，解码器 D_ψ 由潜变量重构图片。概念标签 $\widetilde{\ell}_i$ 由观测训练标签的均值和标准差标准化，用于锚定节点身份：

$$\mathcal{L}_{\text{enc}}(x_i, \ell_i) = \mathbb{E}_{z\sim q_\theta(\cdot|x_i)} \|D_\psi(z) - x_i\|_2^2 + \beta D_{\text{KL}}\Big(q_\theta(z \mid x_i) \,\|\, \mathcal{N}(\widetilde{\ell}_i, I)\Big). \tag{12}$$

q_θ 为编码后验，D_{KL} 为 Kullback–Leibler 散度，β 为正则权重，I 为单位协方差；两项分别约束重构与标签匹配。训练后冻结编码器，取后验均值 $z = E_\theta(x)$。联合训练的基础解码器记为 D；编码器固定后，可仅用 ID 重构将其后拟合为 D'。校准阶段只更新 T，各对照内部共用同一 D 或 D'，查询时全部冻结。

覆盖未定向边的选靶规则。 令 U_t 为第 t 轮尚未定向的无向节点对集合，$\mathcal{A}_t \subseteq \mathcal{J}$ 为尚未耗尽采集额度的可干预目标集合。覆盖式启发式选择与最多未定向边相邻的目标：

$$j_t \in \arg\max_{j\in\mathcal{A}_t} \sum_{\{p,q\}\in U_t} \mathbf{1}[j \in \{p, q\}]. \tag{13}$$

t 为采集轮次，$\mathbf{1}[\cdot]$ 是指示函数，arg max 返回最大覆盖量的目标集合。RGB 逐项更新组（附录 D.3）以最小节点编号破同分；$\mathcal{A}_t$ 包括已采集块数小于 6 的全部目标，每块 1800 条，最多六块，空集时停止。重复目标允许，且无额外的更小目标上限；在六块总上限下，每目标六块上限不会提前约束选靶。该组不采用未定向邻接回退，也不放宽采集额度。设定值从预定 ID 命令分布抽样，不读取真图或测试结果，新图片经过冻结的 h。覆盖启发式不具有已证明的预算最优性。

线性局部机制与岭回归。 局部机制在与 $q_j(u)$ 相同的 h 坐标中拟合，仅对有效、无环且未定向边数为零的估计图执行（附录 B.1）。带截距的线性参数化为

$$h_j = \widehat{f}_j(h_{\text{Pa}_{\widehat{G}}(j)}) + \eta_j, \qquad \widehat{f}_j(v) = c_j + a_j^\top v. \tag{14}$$

v 为父节点读数向量，c_j 为截距，a_j 为系数向量，$\top$ 表示转置，η_j 为加性残差。c_j, a_j 由岭回归估计；拟合 j 时排除直接干预 j 的记录，因为其机制已被替换。根节点观测值与拟合残差存为样本池。线性机制是校准坐标中的预测近似，不由可逆性保证；非线性 T 可能改变局部关系及残差与父状态的依赖，故读数、传播后果与反事实分别评价（附录 B.6）。

B.4 分布预测与个体反事实的实现细节

两条入口共享冻结的编码器 E_θ、校准 T、坐标统计量、有效 DAG$\widehat{G}$、局部机制 $\widehat{f}_j$ 和解码器 D_ψ，*按是否固定一个已观测事实情境*采用不同的条件信息与残差处理，无需重训。以下给出线性机制实现及物理仿真的条件均值分支。

共享映射规定了计算接口，并不自动保证直接干预、其他节点干预和自然观测三种来源上的读数同样准确；跨来源验证见附录 C.2，独立图像读出验证见附录 D.3。非线性校准也不保证保留线性加性机制族，因此读数 MSE 下降与 CF 误差下降需要分别检验。

执行条件与计分集合。 严格入口要求整张估计图有效、无环且没有未定向边；否则该种子/配置的全部事实与总体查询均阻断，不单独挽救看似可识别的目标。下游误差只描述已执行查询。附录 D.2和D.3分别报告其可执行/计划种子数，但这些分母不能确定主表的查询分母或共同计分集合（附录 A.2），种子级分母也不能替代查询级可回答率。配对消融使用共同有效种子。附录 C.3的一致扩展仅用于静态图后端对照，不解除本入口的阻断条件。

B.4.1 给定事实图片：个体反事实解码

输入与预处理。 给定事实 RGB 图片 x、目标 j 和核验设定值 u，计算 $z^{\text{fact}} = E_\theta(x)$ 及 $h^{\text{fact}} = h(x)$；环境值 u 经训练锚点标准化 α_j 及图坐标转换得到 $q_j(u)$。所有来源均使用相同冻结映射，不在测试集重估均值或方差。

事实残差。 对每个非根节点计算

$$\eta_k^{\text{fact}} = h_k^{\text{fact}} - \widehat{f}_k(h^{\text{fact}}_{\text{Pa}_{\widehat{G}}(k)}). \tag{15}$$

这是拟合机制的残差近似，不是已知真实外生扰动。非目标根节点保留事实读数，不引入新噪声；阻断时不以测试真图补齐估计图。

执行干预与保持无关变量。 令 $\mathcal{D}_j = \mathrm{De}_{\widehat{G}}(j)$ 为目标后代集合。先复制事实向量，再设置目标值，按照拓扑顺序更新后代：

$$h_k^{\mathrm{cf}} = \begin{cases} q_j(u), & k = j, \\ \widehat{f}_k(h^{\mathrm{cf}}_{\mathrm{Pa}_{\widehat{G}}(k)}) + \eta_k^{\mathrm{fact}}, & k \in \mathcal{D}_j, \\ h_k^{\mathrm{fact}}, & k \notin \mathcal{D}_j \cup \{j\}. \end{cases} \tag{16}$$

操作切断目标原机制，并非将所有受影响变量设为同一个 u。非目标、非后代按模型图保持事实值；图漏边或错误定向也可能使该保持规则出错。

回到解码器坐标。 图接口标准化首先被撤销，再逆转校准：

$$z^{\mathrm{cf}} = T^{-1}(\sigma^c \odot h^{\mathrm{cf}} + \mu^c), \qquad \widehat{x}^{\mathrm{cf}} = D_\psi(z^{\mathrm{cf}}). \tag{17}$$

解码器接收的是其训练坐标 z，不是未经转换的 h 或物理状态。可逆性解决坐标兼容性，不保证外推点位于准确解码区域。模型不读取 GT 反事实图像或真实后果状态，也没有使用配对后果预测头替代本入口。

刚体条件均值分支。 刚体条件均值传播对照不作数值校准，重新计算后代时不添加式 (16)的事实残差。两种传播方式共享编码、图和解码接口，分项结果见附录表 A3。二值事件可能丢失隐藏初始触发信息，条件均值传播因此可能错误改变事实情境中独立倒伏的后代。

B.4.2 只给定命令：干预分布预测

训练机制及采样池。 在图指定的父集合上拟合带截距的岭回归；拟合节点 k 时排除直接干预 k 的记录。线性机制的岭系数为 10^{-3} 且不惩罚截距。根节点保存观测编码样本，非根节点保存拟合残差。模拟时各节点从对应经验池有放回采样；这是模型的采样近似，不能据此断言视觉残差等于独立的真实物理噪声。

生成样本。 输入仅为操作 $a = (j, u)$，目标是估计干预分布的非目标状态均值；没有事实 x，故不沿用 η^{fact}。令 M 为预测采样总数，对每个 $m = 1, \ldots, M$ 生成 $h^{(m)}$。记 $\widetilde{r}_k$ 为根节点 k 的训练观测池读数，$\widetilde{\eta}_k$ 为训练残差池中有放回抽取的残差，沿拓扑次序计算

$$\widetilde{h}_k = \begin{cases} q_j(u), & k = j, \\ \widetilde{r}_k, & k \neq j,\ \mathrm{Pa}_{\widehat{G}}(k) = \varnothing, \\ \widehat{f}_k(\widetilde{h}_{\mathrm{Pa}_{\widehat{G}}(k)}) + \widetilde{\eta}_k, & k \neq j,\ \mathrm{Pa}_{\widehat{G}}(k) \neq \varnothing. \end{cases} \tag{18}$$

$\widetilde{h}_k$ 为对应的预测节点值，重复采样得到结算分布。采样数、随机种子、操作范围及模型配置由协议固定，不随测试表现改变；图、表示与机制冻结后，才用未参与选型的命令分布变化评价泛化。这里的次序是变量求值次序，不是物理时间。指标定义与逐场景测试分布的解释限制分别见附录 A.6和A.8。空图对照的采样算子另见附录 B.2。

平均与解码顺序。 状态预测按 $\widehat{s}^{(m)} = \mu^s + \sigma^s \odot (\sigma^c \odot h^{(m)} + \mu^c)$ 还原标签单位，等价于逐分量的 $\widehat{s}_j = \mu_j^s + \sigma_j^s T_j(z_j)$；对每个非目标节点取样本平均，得到 $\widehat{\mu}_k(j, u) = M^{-1} \sum_{m=1}^{M} \widehat{s}_k^{(m)}$，$k \neq j$，实际计分单位由任务协议固定。图片生成需逆校准返回原 z 坐标，逐样本解码后平均：

$$\overline{x}_{\mathrm{pred}} = \frac{1}{M} \sum_{m=1}^{M} D_\psi\Big(T^{-1}(\sigma^c \odot h^{(m)} + \mu^c)\Big). \tag{19}$$

因为解码器与校准一般非线性，式 (19)不能替换为“先求平均潜变量再解码”。原编码器坐标均值也在逆变换后计算。GT 分布均值来自允许环境在同一干预命令下的独立采样，不要求与每个模型样本一一配对。

评价含义。 原编码器坐标与均值图片协议和状态 NMSE 分别计分。先对生成样本求平均，再比较预测与 GT 的均值图片，衡量的是总体平均外观，而非每个个体后果是否对应正确。原编码器坐标指标比较两组图片经同一冻结编码器读出的均值，不是独立物理状态误差。SCM 实验的 ID 命令为 ± 1.15、预定幅度变化为 ± 1.75；由于训练命令高斯分布具有全支持，这里是幅度分布变化，不是严格支持集外推。该入口能够计算新命令的 what-if 后果，但反事实示例或重构质量不能替代对 OOD 准确性的评价。

B.5 操作值与视觉读数的查询接口

正文图 3展示完整学习流程。图 A2补充冻结模型中的事实条件反事实查询，说明视觉读数与核验操作值如何进入同一计算坐标，以及预测如何返回解码器的训练坐标。

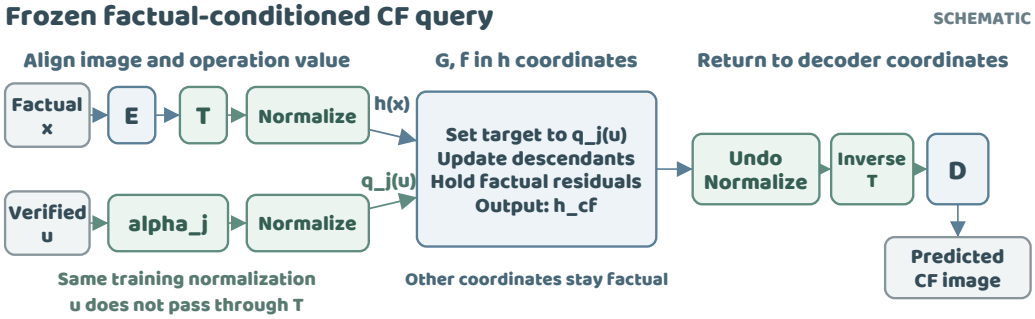


图 A2: 事实条件反事实查询的坐标转换（示意）。图片经 E, T 得到校准读数，核验值经 α_j 转换；两路使用同一观测归一化，分别得到 $h(x)$ 与 $q_j(u)$，后者不再通过 T。设定目标、保留事实残差并更新后代后，撤销归一化、逆转 T，再由 D 解码。E, D, G, f 分别简记编码器、解码器、估计图与局部机制。全部映射和统计量冻结。无事实输入的总体预测见第 4.3节。

B.6 校准坐标与机制近似

可逆校准保证查询能够返回 decoder 的原坐标，并不保证指定的回归函数族在变换后保持不变。为说明区别，暂略去仿射标准化，设原读数关系为 $z_j = f_j(z_{\mathrm{Pa}(j)}) + e_j$。变换后的精确关系为

$$\widetilde{z}_j = T_j\left[f_j\left(T^{-1}_{\mathrm{Pa}(j)}(\widetilde{z}_{\mathrm{Pa}(j)})\right) + e_j\right].$$

这里 $\widetilde{z} = T(z)$; $T^{-1}_{\mathrm{Pa}(j)}$ 逐维作用于父节点。若 T_j 非线性，同一 e_j 带来的增量 $T_j(m+e_j)-T_j(m)$ 通常依赖 $m = f_j(z_{\mathrm{Pa}(j)})$。因此，变换后重新拟合的线性加性模型是近似，不可由可逆性推出残差仍与父状态独立，或个体噪声已被识别。

对于正仿射 $T_j(z_j) = g_j z_j + b_j$，精确矩标准化会抵消图片读数 h_j 中的尺度与偏置（暂不计数值稳定项）。命令设定 $q_j(u)$ 仍通过式 (5)中的 μ^c_j, σ^c_j 依赖这些参数，因此图片坐标不变不代表查询不变。非线性校准可能使失真的视觉关系更接近所用机制族，但并无保证，读数、机制和端到端查询的准确性须分别评价。

B.7 冻结记录上的定向与机制诊断

该组使用种子 5、6、7 的既有编码器、校准和主动采集记录，不训练新模型。恒等、充分拟合仿射和非线性校准共享图采集记录；逐前缀回放固定阈值与差距，并比较升序、降序及 30 个预定随机边顺序。排列是算法诊断条件，不作为独立训练种子。另比较要求两个方向均有超过 30 条记录且读数有非零方差的证据保护；该保护作为独立对照，不改变主表后端。

机制诊断使用每种子的 64 个留出 ID 事实读数。各非根节点报告冻结局部机制的残差及其与父读数的关系；父读数分箱边界只由训练观测确定。残差不是真值预测误差，其依赖可能来自视觉误差、机制错设或有限样本，不能唯一归因于校准。纯坐标诊断对固定原坐标残差分位数，计算变换后增量随父状态变化的标准差；恒等和仿射提供数值零自检。

默认回放与封存图逐项一致。种子 5 的最终前缀为 1800 条记录，种子 6、7 各为 3600 条，因而表中不是跨种子等量预算比较。在这些记录上，改变遍历顺序未改变最终图；该结果不证明任意图或数据下的顺序无关性。要求双侧有效证据使种子 5 保留 6 条未定向边，其余两种子仍可执行查询。保护能够拒绝常量和单侧弱证据，却会损失有限预算下的定向覆盖，因而将其与主表算法分开评价。退化输入测试还显示，原规则可把 31 条单侧常量记录解释为反向候选；这说明数值有效性与图一致性是不同的检查。

表 A4: 冻结诊断。图列为最终采集前缀，三种坐标均得到相同结果；每格在 32 种遍历顺序下均不变。SHD 将未定向真边计为一次未解决关系，故不等于错误箭头数。末列为非线性变换后的固定原残差增量 SD，对非根节点和三个训练残差分位数等权平均；单位为训练标签标准化坐标。它是坐标诊断量，不是预测误差。

种子	原规则 SHD	双侧保护 SHD	双侧保护未定向边	非线性增量 SD
5	0	6	6	0.0343
6	0	0	0	0.0311
7	0	0	0	0.0306

恒等和仿射的固定残差增量 SD 均在 10^{-10} 容差内为零，非线性结果见表 A4。每种子对 6 个非根节点、3 个训练残差分位点的 18 项 SD 取平均；每项在 64 个事实间计算，不是跨种子 SD。这提供了变换后加性解释发生变化的具体例子，但不证明该变化是下游误差的主因。不同坐标下的局部残差不能替代共用环境真值的后果评价。

C 环境干预与结构定向

C.1 多环境结构协议与消融

各环境共享流程，但状态生成方式、数据量和定向判据不同。

环境与统计对象。 Domino-MEC 为七节点链，PnP-MEC 为六变量抓取放置系统，Balance-MEC 为五变量平衡系统，Gears-MEC 为六变量传动系统。显式 SCM 生成响应，渲染器在执行器返回固定 HOME 姿态后提供结算帧，统计检验排除动作过渡帧。机械臂展示操作语义，不意味着全部 SCM 后果由接触动力学产生；刚体四事件多米诺则通过物理接触结算，按附录 A.9单独评分。

训练标签建立节点对齐编码；图发现使用冻结编码后的观测、干预图片和已知目标，不输入真骨架。留出推断中真图仅供离线计分；校准种子的判据选择使用图参考，详见下文。正文表 1报告学习初始部分图的 learned-CPDAG 模式，排除给定真 CPDAG/DAG 的诊断。结构与反事实实验各用固定种子清单；Domino 结构留出与机制查询也各有种子和协议。

Domino-MEC：独立留出与定向判据。 图恢复使用留出种子 20–27，与开发种子 0–9 和判据选择/校准种子 10–17 分离；后者不是数值 T 校准种子。噪声上界拟合不使用真图，但判据选择依据校准真图评价留出折预测。冻结判据采用置信度 0.99、2000 次 bootstrap、最少 200 条记录、附加零效应余量 0.03、信号超额 0.10 和方向对比 0.15。余量叠加于各目标噪声上界，不是零效应区间；单侧/双侧检验及选型规则见附录 B.2。输入为 6000 张观测、每干预块 1800 张图片，编码器训练 350 轮，最多六轮选靶。8 个留出覆盖运行均在两轮内完成；轮次指采样块，调用按返回记录计。

共享留出种子、冻结 encoder、观测初始 CPDAG 及目标/块索引缓存时，未定向边覆盖（coverage）、随机（random）、固定轮转（round-robin）的终态完整恢复均为 8/8，仅观测（passive）为 0/8，每次仍保留 6 条未定向边。共享缓存项像素相同，但图状态变化可改变后续目标和实际轨迹。每轮从初始 CPDAG 以累计证据重算，逐项接纳方向并作 Meek 闭包。该终态消融不证明等预算策略优势。将 coverage 置信判据替换为固定阈值 $\tau = 0.15, \delta = 0.05$ 后完整恢复为 4/8，仍保留错误和未决状态。

PnP-MEC、Balance-MEC 与 Gears-MEC。 PnP 使用独立留出种子 200–207，初始 CPDAG 与最终 DAG 均为 8/8，最终错误和未定向边均为 0。Balance 使用 8 个开发配置种子，骨架效应阈值在诊断额外邻接后由 0.04 调整为 0.06，冻结编码器复用；最终 7/8 正确，另一例保留额外邻接。因此，Balance 结果属于开发样本分析，不构成独立留出泛化的证据。Gears 使用种子 0–7，4200 张训练图片、5000 张观测图片、每块 900 张干预图片、180 轮编码器训练；观测骨架阈值 0.06，定向阈值 0.20 与差距 0.08。8 个学习图运行均一轮消除 3 条方向歧义，错误箭头为 0；被动对照终态仍各有 3 条未定向边。

与统一接口的关系。 共享流程为视觉编码、观测部分图、选靶、干预证据及图更新，判据按环境冻结；结果反映结构流程，而非额外非恒等校准器的贡献。附录 C.3允许协议固定的

一致扩展以完成下游计算，不计为识别成功；附录 B.4的严格查询入口不允许该操作。因子后果 NMAE、像素反事实 MSE 和分布预测误差分别计算，不互相替代。

C.2 按需采集与冻结校准查询

本组在七节点多米诺场景（64×64 彩色图像）及编码器种子 5、6、7 上分别评价证据获取、读数与查询后果。编码器、解码器、校准、训练统计量和计分方案均在测试数据生成前冻结，不按测试误差选型；结论限于此模拟环境。

C.2.1 相同记录数量下，新增观测与干预提供什么信息

各组共享 6000 条观测、896 条校准记录及冻结非线性映射。追加独立观测按 1800 与 3600 条前缀重估 PC；干预组从相同初图出发，以覆盖或固定轮转选靶，每批 1800 条、上限 3600 条，在图有效且充分定向时停止。每个已到达的干预前缀均配对等量新观测。双方计入同一校准成本，但校准记录不进入图阶段证据；比较仅隔离*图阶段的证据来源*，不是全流程无干预对照。

不一致的候选方向批整体拒绝，规则与阈值在采集前固定；本组与附录 F.1、F.3均使用相同的批量提交实现，有别于附录 B.1的逐项提交。真图仅对固定轨迹计分，不进入选靶、停止或图估计。

三组采集运行的对应关系。 上述三组在每个训练种子内复用相同的编码器检查点、6000 条观测及非线性 T；冻结清单中的文件哈希相同，初图也逐字段相同，均为含 6 条未定向边的七节点链。相同训练种子不表示相同图阶段样本。目标 j 的第 b 批以 $N+10007s+101j+b$ 作为采样种子，其中 $s \in \{5, 6, 7\}$，j, b 从 0 计数。本节的等记录证据对照使用 $N = 142000000$，附录 F.1的三策略对照使用 $N = 2600000$，附录 F.3的同总预算对照使用 $N = 12600000$。三组均从空图干预池开始，并保持相同 ID 命令分布与定向阈值；本节图记录上限为 3600，另两组的非线性配置为 10800。

表 A5: 同一冻结视觉与校准接口下的图证据来源对照。各行比较相同新增记录数；896 条校准记录在双方共同计入，6000 条初始观测相同。干预与追加观测的图在相同前缀计分，不将早停后未采集的记录视为已有证据。

采集策略	种子	新增记录	干预 SHD	追加观测 SHD
覆盖选靶	5	1800	0	6
固定轮转	5	1800	0	6
覆盖选靶	6	3600	0	6
固定轮转	6	1800	0	6
覆盖选靶	7	3600	0	6
固定轮转	7	1800	0	6

两种干预策略在 3 个种子上均恢复真图；等量追加观测留下 6 条未定向边，而非 6 条错误方向。轮转每次使用 1800 条干预记录，覆盖在两个种子上用到 3600 条。结果支持干预提供额外定向信息，不支持覆盖的预算优势或仅观测普遍无法定向。

种子 6 的覆盖轨迹说明了跨表差异：本节先采目标 1、再采目标 0，在 3600 条图记录后接受 $0 \to 1$ 并完成定向；另两组在相同目标前缀后仍保留 0–1，随后重复采目标 0 直至耗尽预算。后两组固定的目标 1 样本分别给出 0.15265 和 0.15226 的反向响应分数，均高于阈值 0.15，因而双侧规则持续弃权。这里的 3/3 与另两组的 2/3 对应不同的已指定图采样流，并非更换校准检查点或提交规则；不能把本组 3/3 解释为覆盖策略跨采样重复均稳定成功。

C.2.2 校准读数能否迁移到其他响应来源

每种子以 512 个独立外生情境生成自然观测和 7 种直接干预，取原 ID 干预值。三个校准配置共享冻结编码，目标状态 GT 来自 SCM。各节点评价直接操作、自然观测和其他节点干预三类来源；后一类含祖先及非祖先，记录另分层祖先子集，不统称为间接因果效应。

误差覆盖全采样范围及共同箱：共同箱预定为训练标签标准化坐标 $[-2, 2]$ 内间隔 0.5，仅保留每来源至少 8 条的箱，先对箱、再对节点等权。所有种子均有 7 个可计分节点，范围、计数和排除记录均保存。GT 仅作评价分层，不更新映射，也不保证箱内分布相同。

表 A6: 跨来源读数 MSE，数值为原误差乘 10^3，报告 3 种子的均值 ± 样本 SD；每种子对 7 节点等权。共同箱按训练标签单位固定分箱，每节点每箱在三来源均至少 8 条，再对共同箱等权；只控制粗粒度共同支持，不是完全分布匹配。粗体为各面板最小点估计，不表示统计显著。

校准	直接干预该节点	自然观测	其他节点干预
全采样范围			
无校准	23.636 ± 2.994	36.850 ± 7.400	39.063 ± 6.405
充分拟合仿射	15.224 ± 0.399	$\mathbf{33.258 \pm 3.868}$	$\mathbf{36.365 \pm 2.890}$
非线性校准	$\mathbf{12.998 \pm 0.233}$	35.144 ± 3.376	38.296 ± 2.306
固定共同箱			
无校准	22.953 ± 3.222	30.711 ± 7.441	29.878 ± 5.482
充分拟合仿射	14.321 ± 0.602	18.321 ± 2.813	18.961 ± 1.251
非线性校准	$\mathbf{12.306 \pm 0.403}$	$\mathbf{14.806 \pm 1.860}$	$\mathbf{16.260 \pm 0.688}$

表 A6中，非线性的三来源共同箱误差均值最低，但全范围的观测和其他节点干预以充分拟合仿射更好，读数收益仍受状态范围影响。共同箱不等于完整分布匹配，来源误差仍不同，不能据此断言来源差异已消除。

C.2.3 从校准坐标到真实状态与图片查询

查询使用同记录对照中无校准、充分拟合正仿射及非线性组的冻结图和机制，不换成上述采集策略的图。种子 6 在三组均有未定向边，保留计划分母但阻断查询；种子 5、7 的图相同且可执行。

每有效种子含 64 个新事实情境、7 个目标，ID 命令为训练标签均值 ± 0.75 标准差，幅值命令为 ± 2 标准差，每类 896 个 CF 查询。GT 重放同一外生情境；模型只接收事实图片、目标和值，保留事实残差、逆校准后解码。总体查询不固定事实图，模型与 GT 各取 4096 个经验池/SCM 样本的均值。各模型共享测试情境与随机种子，幅值测试不调整模型。

预测按训练概念尺度换回环境单位，与 SCM 状态比较后按该尺度归一化。CF 状态列评价个体后果，总体列评价第 3节中各非目标节点的干预均值 $\mu_k(j, u)$，$k \neq j$；均排除设定目标，不把命令复制计为预测成绩。后代、非后代及相对事实变化误差另存。状态指标不是独立 decoder 语义读数；图像指标为原始浮点解码输出的像素 MSE。

表 A7: 冻结图、机制与 decoder 的查询结果，数值为原误差乘 10^3。状态列以真实模拟器状态为 GT 并排除直接目标；图片列为自身 decoder 输出的 MSE。报告共同有效种子 5、7 的均值 ± 样本 SD，计划 3 种子，seed6 因冻结图未充分定向而阻断。粗体为同命令组最小点估计；幅值变化不是严格支持外推。

校准	命令	CF 状态 NMSE	总体均值 NMSE	图片 MSE
无校准	ID	37.303 ± 8.593	3.366 ± 2.889	2.257 ± 0.025
充分拟合仿射	ID	$\mathbf{32.810 \pm 3.066}$	$\mathbf{1.758 \pm 0.025}$	$\mathbf{2.232 \pm 0.023}$
非线性校准	ID	34.875 ± 1.268	2.045 ± 0.176	2.237 ± 0.019
无校准	幅值变化	38.396 ± 8.949	3.983 ± 3.330	1.699 ± 0.039
充分拟合仿射	幅值变化	$\mathbf{35.102 \pm 2.667}$	3.756 ± 0.321	$\mathbf{1.688 \pm 0.043}$
非线性校准	幅值变化	36.703 ± 0.869	$\mathbf{3.492 \pm 0.510}$	1.692 ± 0.048

共同可执行的 2 种子中，非线性相对无校准的非目标 CF 状态 NMSE 均值在 ID/幅值下分别降低 6.51%/4.41%，总体均值 NMSE 降低 39.26%/12.33%。降幅不稳定：两类查询误差均在种子 5 上升、种子 7 下降。相对充分拟合仿射，仅幅值总体均值误差较低，其余列均较高；均值排序不代表统计显著性。

若评价相对事实的变化量，非线性相对无校准的非目标效应 NMSE 在 ID/幅值下反升 0.88%/11.77%。绝对状态、变化量、总体均值和图片误差衡量不同能力；结合阻断的种子 6，本组验证冻结接口的可执行查询及范围受限的读数收益，不支持稳定端到端校准优势。

C.3 四任务 MEC 静态机制对照

本组采用 Domino-MEC、PnP、Balance-MEC 与 Gears-MEC 的固定静态实例，编码器按原生协议训练，各用 8 个种子，PnP 为留出种子 200–207。环境内固定视觉表示与机制函数族，仅改变图接口；贪心干预等价搜索（GIES）(Hauser & Bühlmann, 2012) 和被动图扩展接收与本文方法相同的数值表示。指标为反事实因子级 NMAE，即变量后果的归一化绝对误差，而非像素误差。这些图后端/机制对照独立于正文 RGB 及刚体图像基准，不评价图片 MSE 或动态图预测。

表 A8: 静态因子级反事实 NMAE，越低越好。均值与 95% bootstrap 区间来自对应的逐种子记录；不同归一化定义的指标不合并排名。

方法	Domino	PnP	Balance	Gears
本文方法	0.1745 [0.1650, 0.1855]	0.1345 [0.1251, 0.1452]	0.0886 [0.0771, 0.1041]	0.1021 [0.0995, 0.1045]
GIES	0.2716 [0.1750, 0.3939]	0.1319 [0.1235, 0.1413]	0.0894 [0.0781, 0.1049]	0.1018 [0.0998, 0.1037]
被动图扩展	0.6975 [0.6841, 0.7094]	0.1345 [0.1252, 0.1448]	0.5966 [0.4478, 0.6782]	0.7199 [0.7024, 0.7374]
打乱图	0.4824 [0.4183, 0.5600]	0.8287 [0.7532, 0.9065]	0.6069 [0.5283, 0.6883]	0.6478 [0.5312, 0.7558]
无图传播	0.6975 [0.6841, 0.7091]	0.9662 [0.9486, 0.9865]	0.9418 [0.9290, 0.9552]	0.9081 [0.8879, 0.9315]
给定真图（结构参考）	0.1745 [0.1650, 0.1858]	0.1345 [0.1253, 0.1448]	0.0886 [0.0770, 0.1043]	0.1021 [0.0995, 0.1045]

“被动图扩展”按预定规则从观测图选择相容 DAG；“打乱图”改变节点对应，“无图传播”移除变量间传递。部分图的协议固定一致扩展仅供计算，不算干预识别。给定真图仅作结构参考，机制仍由相同视觉编码数据拟合。PnP 与 Gears 中 GIES 的误差点估计略低，Domino 与 Balance 中本文方法较低，比较受所报区间和任务条件限定。

Balance-MEC 的骨架效应阈值由开发样本选择，有别于 PnP 的独立留出种子 200–207；结果保留各环境的选型与评价范围。

C.4 三场景 WHAT-IF 与像素反事实协议

PnP、Balance、Gears 原生 MEC 实现各用种子 300、301，并采用学习型 T；图发现和查询阶段冻结编码器、校准映射与归一化统计量。结构学习与正文实现相同，但种子清单及分母独立。PnP 按训练锚点验证误差从 3 个编码器初始化中选择；Balance 用冻结骨架阈值 0.06、90 轮训练，Gears 用 180 轮。图发现接收像素编码而非真图；查询要求图完全定向且无环，不按离线 SHD 选种子。六个运行均保留：PnP/Gears 各执行 2/2，Balance 为 1/2，种子 301 因方向歧义阻断。误差仅对有效运行统计，阻断不填零。

机制预测。 局部岭机制使用同一冻结视觉接口处理 ID 观测与原选靶干预记录，排除各节点的自身干预样本。根节点从观测读数池、非根节点从拟合残差池有放回采样。参数在预测前固定，不按 ID/OOD 测试查询选型。每节点各设两个 ID/OOD 命令，位于训练映射物理原点 $\pm 0.75/\pm 2$ 尺度；两方法共享原数据适配层（adapter）的训练归一化尺度，测试后果不决定命令或分母。

无图总体对照以相同编码记录与掩码新建空邻接模型，各节点均为根，从各自观测边际池独立有放回采样（无观测池时退回未干预该节点的记录），再钳制目标；不复用父系数或残差池。遍历顺序不同，共同随机种子不代表逐坐标噪声配对；实现见附录 B.2。

对目标 j 和命令 u，令 $\bar{s}^{\mathrm{GT}}$、$\bar{s}^{\mathrm{pred}}$ 为本协议计分单位下模拟器与模型的 2048 样本均值，d_k 为训练固定尺度：

$$E(j,u) = \frac{1}{K-1} \sum_{k \neq j} \left(\frac{\bar{s}_k^{\mathrm{pred}} - \bar{s}_k^{\mathrm{GT}}}{d_k} \right)^2 . \tag{20}$$

每有效种子对目标及正负命令等权，再报告跨种子均值与样本 SD；Balance 仅报唯一有效种子的点值。排除设定目标以免奖励命令复制，保留非后代以同时衡量传播与保持。退化倍数 $g = E_{\mathrm{OOD}}/E_{\mathrm{ID}}$ 越低表示相对误差增长越小，与表 3的稳定性比值相反：仅相同误差汇总满

足 $r = 1/g$。运行集合不同，不能跨协议取倒数。原始记录另存最坏查询及分布标准差误差。本协议检验干预幅度变化，不衡量严格支持集外泛化或完整分布距离。

图像查询。 沿用 encoder、已学图与机制，decoder 在 2400 个独立 ID 观测及其冻结编码上拟合重构，固定 200 轮、batch256、Adam 学习率 0.001，不用测试事实–反事实对。两方法共享 decoder；本文设定事实目标、保留残差并传播到后代后解码，空图对照仅设目标，保持其余事实坐标，不作池采样。GT 以相同外生噪声重放。32 个固定情境、K 目标及两命令共 $64K$ 查询。生成图像均为 decoder 输出，模拟器仅供事实图及配对 GT。

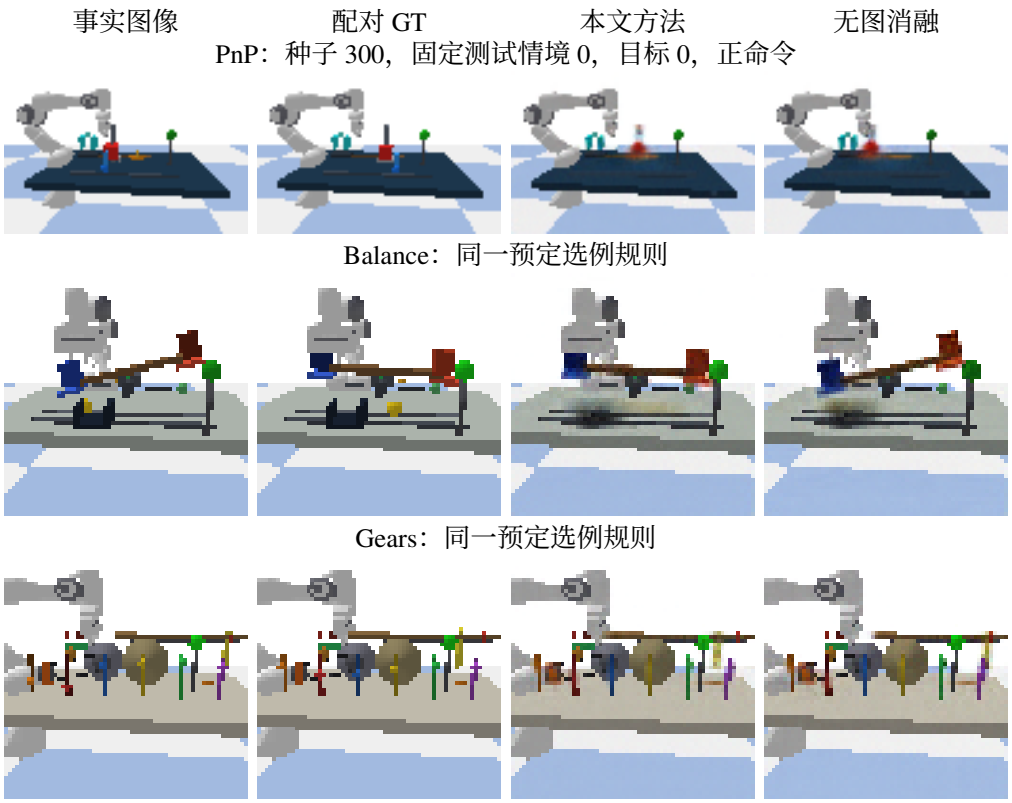


图 A3: 三种受控 MEC 场景的固定查询。案例按测试索引预定选择，不以预测质量筛选。PnP 为 64×96，Balance/Gears 为 64×64；该组不与刚体多米诺或 RGB128 图像协议合并。

该实现内的图对照受场景规模、有效种子数及阻断率限定。无图消融不是已发表的独立模型，不据此推断对 CausalVAE 的跨场景优势。

D 操作值校准与查询能力

D.1 操作值校准的查询指标与结果解释

正文表 2以同一三种子组比较读数、效应及 RGB，指标和更新权限如下。

反事实效应误差。 单个查询的非目标事实–反事实变化误差为

$$\frac{1}{K-1}\sum_{k\neq j}\left[\frac{(\widehat{s}_k^{\mathrm{cf}}-\widehat{s}_k^{\mathrm{fact}})-(s_k^{\mathrm{cf}}-s_k^{\mathrm{fact}})}{\sigma_k^s}\right]^2.$$

它有别于绝对状态 NMSE 及不固定事实图的总体均值 NMSE。表 2报告读数、效应和 RGB 误差；总体均值、图发现与独立图像读出另行评价。

更新权限与比较范围。 无校准、充分拟合仿射和非线性共用 ID 重拟合 decoder；普通联合更新同时改变读出头及 decoder，不能将差异单归于可逆性、参数量或某损失项。正文均值和 SD 先在种子内对目标及命令等权，再跨种子统计；改善种子数和配对差见附录 D.4。

其他对照中的取舍。 附录 D.3使用原 decoder 和逐项方向更新，正文组使用 ID 后拟合 decoder。各组独立固定测试情境，组内校准配置共享 decoder，读数、效应和 RGB 不跨组拼接。仅替换 decoder 的对照见附录 E.1。

D.2 冻结解码器下的受限仿射与非线性校准

独立 ID 验证复用七节点多米诺场景（64×64 彩色图像）种子 5、6、7 的冻结 encoder/decoder、6000 观测、896 条目标记录及共同覆盖选靶数据，无新训练或 OOD 选型。各组使用自身归一化、冻结图和机制；图基于同证据，不重采样。

受限正仿射固定曲率权重为 0，非线性增加严格单调项，共享学习日程和数据权限。无校准组不拟合 T，也不把节省的校准预算转给图发现。

全部九个 T、图和机制在验证前冻结。每种子 7 目标各 64 条独立随机 ID 干预读数，共 1344 条。图有效种子另用 64 个独立事实情境，7 目标各两条训练锚点均值 ± 0.75 标准差命令；三组共享事实图和命令，GT 固定外生情境重放。各组在自身冻结坐标/机制中保留事实残差、逆 T 后接冻结 decoder，预测器不接收 GT 状态。

seed6 各组均留一条未定向边，阻断 CF，不任意补图或填 0。读数/图分母 3，CF 共同分母 2，每有效种子 896 个配对查询。3264 次评价调用含 1344 读数、1792CF GT、128 事实记录；另 32 条一致性记录不计，无训练调用。

表 A9中非线性读数最佳，但图恢复不变、像素收益较小，CF 均值略高于受限仿射。逐维可逆映射不增加总体条件独立信息，有限样本及机制拟合变化另论。充分拟合仿射与同总预算对照见附录 F.3。

表 A9: 冻结解码器下的受限仿射与非线性校准对照。ID 读数与 CF 误差乘 10^3，均值 $\pm$ 种子间样本 SD。图列为各组冻结图在种子 5/6/7 的 SHD；seed6 图阻断，不填 CF 误差。

配置	目标 MSE（3/3）	SHD	CF 像素 MSE（2/3）
无校准	23.090 ± 3.183	0/1/0	2.1894 ± 0.0183
受限正仿射	15.036 ± 0.773	0/1/0	$\mathbf{2.1643} \pm 0.0192$
非线性校准	$\mathbf{12.849} \pm 0.798$	0/1/0	2.1707 ± 0.0204

D.3 操作值校准与普通监督更新的同记录验证

本组在七节点多米诺场景（64×64 彩色图像）、编码器种子 5、6、7 上区分读数、数值查询和图像变化，联合评价校准、逐项图更新、局部机制及两类查询；图均由本组采集记录学习。

D.3.1 共同数据与更新权限

每种子复用冻结基座、6000 观测及 896 核验记录，以原种子和命令重放训练图片、逐项核对保存编码，不新增独立数据。无校准、充分拟合正仿射、非线性共用冻结 encoder/decoder；非线性七坐标各含增益、偏置、五基函数权重，共 49 系数。

普通联合更新是同监督控制，非已发表方法。冻结卷积特征后，在 256 维特征上重拟合七个线性头，共 1799 参数；新增标签仅为直接目标核验值，观测保持权重 0.01。原 896 记录内四折交叉验证从 $\{10^{-4}, 10^{-2}, 1\}$ 选岭系数，再拟合全部记录。共同 decoder 检查点仅重构 6000 观测和 896 校准图，训练 40 轮、batch128、Adam 学习率 10^{-4}，取固定末轮；其 1,154,659 参数不接收测试 CF 配对。共享数据标签但可更新模块/参数量不同，不能单独归因于读出头或 decoder。

表 A10汇总这些更新权限下的读数与查询；其原 decoder 和测试查询有别于表 2的 ID 后拟合 decoder 与查询，不合并两组。

D.3.2 从新采集图到冻结查询

视觉接口冻结后，非线性组按正文覆盖规则选靶，每批 1800 条新像素、最多六批。按附录 B.1逐项试加方向、检查一致性并作 Meek 闭包，不用批量提交。其他配置接收实际采集的相同图片及命令，在自身坐标中学图、拟合局部线性机制；记录匹配，不代表四组各自优化主动策略。

三种子使用 1800、3600、3600 条图记录，各组计入 896 校准记录，观测另列。停止不读真图，模型冻结后才评分。四组的三种子均为 SHD 0 且无未定向边，查询全可执行，不支持校准提高恢复率。批量提交的 2/3 分母属于不同更新过程，不直接比较。

每种子含 64 个新事实情境、7 目标、每目标四命令：训练标签均值 ± 0.75 标准差为 ID，± 2 为幅值变化。每种子/split 含 $64 \times 7 \times 2 = 896$ 条 CF，每配置/种子两 split 共 1792 条，三种子 5376 条，独立于 896 训练核验记录。GT 固定外生情境重放，模型只接收事实图及命令。总体评价比较模型/模拟器各 4096 个后果的非目标均值。图、机制、视觉模块和统计量均冻结。

表 A10: 七节点多米诺场景（64×64 彩色图像）同记录、逐项方向更新对照。误差乘 10^3，为三个编码器种子的均值 $\pm$ 样本 SD；各配置均为 3/3 有效种子，每种子每 split 含 896 条 CF 查询。上面板为标准化标签单位的目标读数 MSE，更新模块依次为无、仿射 T、非线性 T、读出头与 D；联合更新同监督但参数量不同。下面板的状态、效应及总体均值 NMSE 排除直接目标。粗体标识可比点估计的最小值，浅蓝标识非线性校准。

配置	无校准	充分拟合仿射	非线性校准	普通联合更新
目标读数 MSE	22.683 ± 4.703	14.377 ± 1.253	12.190 ± 1.201	$\mathbf{8.075} \pm 0.860$

配置	命令	状态 NMSE	效应 NMSE	均值 NMSE	图片 MSE
无校准	ID	35.074 ± 4.111	5.748 ± 0.818	2.932 ± 2.157	2.297 ± 0.043
充分拟合仿射	ID	$\mathbf{33.871} \pm 4.674$	$\mathbf{5.250} \pm 0.405$	$\mathbf{1.830} \pm 0.234$	2.278 ± 0.040
非线性校准	ID	36.884 ± 5.158	5.703 ± 0.248	2.226 ± 0.404	2.285 ± 0.038
普通联合更新	ID	43.699 ± 6.104	10.194 ± 0.856	3.212 ± 0.599	$\mathbf{1.052} \pm 0.021$
无校准	幅值变化	36.469 ± 4.106	7.143 ± 1.173	4.596 ± 2.928	1.747 ± 0.021
充分拟合仿射	幅值变化	$\mathbf{35.764} \pm 5.030$	$\mathbf{7.142} \pm 0.706$	$\mathbf{3.784} \pm 0.103$	1.739 ± 0.027
非线性校准	幅值变化	38.431 ± 5.409	7.250 ± 0.576	3.831 ± 0.209	1.744 ± 0.028
普通联合更新	幅值变化	54.163 ± 8.155	20.658 ± 2.591	13.225 ± 2.447	$\mathbf{0.850} \pm 0.019$

非线性目标读数误差相对无校准/充分拟合仿射降低 46.26%/15.21%，三种子均改善；仿射的数值查询均值仍较低。非线性相对无校准的总体均值误差在 ID 下降 24.10%，仅一种子改善；幅值下降 16.64%，两种子改善，不算稳定收益。相对联合更新，其幅值总体均值误差下降 71.03%、三种子均改善，但联合更新图片误差更低，两类评价不互替。

D.3.3 独立评价生成图片的可见状态

另用不共享权重的独立图像读出器 Q 评价可见激活 $\gamma(s_j) = 1/(1 + \exp(-3.8 s_j))$，不要求从饱和像素任意精确恢复 s_j。节点独立采样以打破因果相关捷径：等概率混合 $\mathcal{U}(0.001, 0.999)$ 与 Beta$(0.5, 0.5)$，裁剪至 $[10^{-5}, 1 - 10^{-5}]$ 后逆映射渲染。其 8192 训练图、1024 独立验证图均不用于四组训练。

Q 采用三层步长 2 卷积（32/64/96 通道）、256 维全连接层及七维 sigmoid 输出；Adam 学习率 10^{-3}、batch128、80 轮，随机加 3×3 平均模糊，仅按清晰/模糊独立验证 MSE 均值选检查点。七节点均通过两类验证的预设门槛（MAE 不超过 0.08、R^2 不低于 0.5）：清晰 MAE 为 0.0066–0.0190，模糊为 0.0066–0.0249。该学习型测量并非无误差。

对直接目标、真实后代或真实非后代集合 A，绝对误差比较 $Q_k(\hat{x}^{\mathrm{cf}})$ 与真实 $\gamma(s_k^{\mathrm{cf}})$，$Q_k(x^{\mathrm{GT}})$ 仅作测量误差基准。变化量以事实重构 $x^{\mathrm{rec}} = D_\psi(E_\theta(x))$ 为参考：

$$\big[Q_k(\hat{x}^{\mathrm{cf}}) - Q_k(x^{\mathrm{rec}})\big] \quad 与 \quad \big[\gamma(s_k^{\mathrm{cf}}) - \gamma(s_k^{\mathrm{fact}})\big].$$

绝对差先在非空 A 内平均，再对目标/命令等权，最后统计种子均值和 SD；空集不记零。真图仅作离线分层。

表 A11: 独立图像读出器评价的可见状态 MAE，数值乘 10^3；均值 ± 跨三个编码器种子的 SD。目标、后代及非后代均对真实模拟器激活量评分；变化量以各模型的事实重构为参考。GT 读出误差另作为测量误差基准报告，不替代真值。粗体为同 split 同列最小点估计。

配置	命令	目标	后代	非后代	后代变化	非后代变化
无校准	ID	219.4 ± 4.7	156.6 ± 5.1	88.6 ± 2.4	123.9 ± 0.5	42.4 ± 3.1
充分拟合仿射	ID	209.8 ± 4.5	155.0 ± 6.0	92.8 ± 3.1	122.1 ± 1.4	47.0 ± 3.1
非线性校准	ID	212.0 ± 4.0	157.2 ± 6.2	92.5 ± 3.0	125.5 ± 1.6	46.5 ± 2.8
普通联合更新	ID	**28.7** ± 2.5	**61.8** ± 4.7	**17.9** ± 0.4	**61.3** ± 2.4	**6.1** ± 0.4
无校准	幅值	77.1 ± 2.9	86.5 ± 2.1	174.2 ± 5.7	149.3 ± 1.9	144.0 ± 6.5
充分拟合仿射	幅值	70.2 ± 3.2	82.9 ± 3.9	181.2 ± 3.6	146.8 ± 3.3	151.7 ± 4.8
非线性校准	幅值	65.1 ± 3.9	81.8 ± 3.8	184.9 ± 3.5	147.8 ± 3.3	156.3 ± 4.5
普通联合更新	幅值	**16.0** ± 1.0	**48.3** ± 2.9	**26.4** ± 1.9	**57.4** ± 1.6	**16.9** ± 2.6

幅值变化下，非线性目标图像读出误差相对无校准/仿射降低 15.52%/7.31%，三种子均改善；ID 以仿射更好。原始 MAE（未乘 10^3）中，非后代误差 0.18491 高于无校准 0.17422 和仿射 0.18121，GT 图误差基准为 0.01335。模型非后代状态跨命令不变，解码图却有较大读出变化，将保持性失败定位于冻结解码路径，而非图恢复或掩码。联合更新缓解该现象，但未隔离读出头、decoder 及二者交互作用。

D.3.4 逐种子结果

表 A12: 同记录、逐项方向更新对照的逐种子结果，误差乘 10^3。同一种子的四配置共享采集像素与测试情境；所有图均为 SHD=0，三个预定种子全部计分。

种子	配置	读数 MSE	ID 均值 NMSE	幅值均值 NMSE	ID 图片 MSE
5	无校准	18.898	1.027	1.969	2.260
5	充分拟合仿射	13.975	1.596	3.826	2.239
5	非线性校准	11.982	1.972	3.803	2.247
5	普通联合更新	7.996	3.446	15.700	1.031
6	无校准	21.204	2.496	4.065	2.287
6	充分拟合仿射	13.374	2.065	3.860	2.276
6	非线性校准	11.106	2.691	4.053	2.284
6	普通联合更新	7.257	3.659	13.168	1.053
7	无校准	27.948	5.274	7.753	2.344
7	充分拟合仿射	15.781	1.828	3.667	2.319
7	非线性校准	13.481	2.014	3.637	2.323
7	普通联合更新	8.972	2.532	10.807	1.073

表 A12保留全部三个预定种子；改善比例均为均值之比。

D.4 正文受控组的种子配对比较

种子 5、6、7 的无校准、充分拟合仿射、非线性组共享固定 encoder、已学图、拟合记录、查询及种子内 ID 后拟合 decoder；原 decoder 另作敏感性条件。每种子 64 事实、7 目标、四命令，共 1792 条 CF；ID/幅值为训练标签均值 $\pm 0.75/\pm 2$ 标准差。统计分母保留全部 3 个训练种子，而非图片数。

$E_{a,s}$ 为配置 a 在种子 s 内对目标和命令等权的误差；配对差 $d_s = E_{a,s} - E_{b,s}$ 为负时 a 更好。表 A13给出 $\bar{d}$、配对样本 SD 及 $d_s < 0$ 的种子数。三种子仅描述该冻结组的重复性，不推定其他表的分母或方差。

非线性相对无校准的两类非目标效应均值均降低，但各一种子变差；幅值 RGB 有 2/3 种子改善，均值却略高。相对充分拟合仿射，幅值效应均值较低，ID 效应及两类 RGB 均较高。均值和改善种子数仅支持条件性校准收益，不支持非线性普遍更优。

表 A13: 正文表 2同一三种子组的配对差。误差与 SD 乘 10^3；括号为改善种子数/3。SD 取逐种子差值，不是两组 SD 相减。

比较（前者减后者）	查询	非目标效应 NMSE 差	RGB MSE 差
仿射 − 无校准	ID	-0.700 ± 0.930(2/3)	-0.042 ± 0.021(3/3)
仿射 − 无校准	幅值变化	-0.202 ± 1.583(2/3)	-0.018 ± 0.020(2/3)
非线性 − 无校准	ID	-0.495 ± 1.022(2/3)	-0.020 ± 0.027(2/3)
非线性 − 无校准	幅值变化	-0.343 ± 1.643(2/3)	0.004 ± 0.023(2/3)
非线性 − 仿射	ID	0.204 ± 0.259(1/3)	0.022 ± 0.006(0/3)
非线性 − 仿射	幅值变化	-0.141 ± 0.261(2/3)	0.022 ± 0.004(0/3)

普通监督更新共享直接目标标签，但更新读出头和 decoder；其状态/效应可按相同查询及物理单位比较，图像结果不能归于仅替换 T。缺逐种子记录的主表点估计不借用本组 SD 或分母。

D.4.1 固定已学图的 Gears-MEC 迁移

Gears-MEC 六节点 $drive \to g_1 \to g_2 \to ptr \to led \leftarrow target$ 含负系数和汇合点，有别于多米诺但仍为线性加性 SCM。种子 300、301 提供独立训练、已对齐的灰度 CNN 及 RGB decoder，输入 64×64。encoder、已学完整图、decoder 均冻结，仅重拟合校准及对应坐标的局部线性机制，不改变前端训练或评价新图恢复收益。

每种子共享原 5000 观测及 900 图干预记录，新增 768 校准记录（每节点两轮、每轮 64 条），仅监督直接目标核验值。非线性沿用式 (3)的五基函数，每轮累计回放 100 步、Adam 学习率 0.01、保持权重 0.01；仿射充分拟合同项。新记录仅供校准，机制仍用原记录及岭系数 10^{-3}。逆校准回到原 encoder 坐标后再作原 decoder 标准化，往返最大误差小于 10^{-10}。

冻结后每种子用 64 个新事实、六目标、四命令，共 1536 条配对 CF；ID/幅值为训练标签均值 $\pm 0.75/\pm 2$ 标准差。每目标另有 64 条 ID 直接读数；每总体查询取 4096 模型样本及 4096 独立模拟器样本。命令单位由训练标签固定，不按测试选择。该划分不替代主表；两独立视觉模型对应 $n = 2$，种子内三种校准共享数据和查询。

表 A14: Gears-MEC 固定图的校准迁移，种子 300/301。全部误差乘 10^3，为均值 ± 种子样本 SD；读数来自独立 ID 核验。三臂同一 D；$n = 2$ 仅作描述性比较。

校准	查询	ID 读数 MSE	非目标效应 NMSE	总体均值 NMSE	RGB MSE
无校准	ID	7.517 ± 1.327	1.239 ± 0.229	0.455 ± 0.152	0.923 ± 0.011
无校准	幅值变化	7.517 ± 1.327	1.556 ± 0.384	0.845 ± 0.632	1.141 ± 0.007
仿射	ID	7.295 ± 1.599	1.347 ± 0.287	0.615 ± 0.323	0.926 ± 0.017
仿射	幅值变化	7.295 ± 1.599	2.001 ± 0.751	1.363 ± 1.135	1.144 ± 0.016
非线性	ID	7.298 ± 1.364	1.396 ± 0.369	0.742 ± 0.471	0.928 ± 0.019
非线性	幅值变化	7.298 ± 1.364	2.324 ± 1.153	1.724 ± 1.581	1.159 ± 0.010

两种校准略降平均 ID 目标读数误差，却升高非目标效应、总体均值及 RGB 均值；非线性幅值效应 NMSE 由无校准 1.556×10^{-3} 升至 2.324×10^{-3}。直接读数改善不保证传播改善，两种子也不足以确定普遍失败条件或单组件归因。

共用 decoder 的 RGB 误差与模拟器状态效应误差分别报告。无独立 Gears 图像语义读出器，不能据此验证生成目标/后代/非后代语义。两预定种子均保留，结果不用于重选校准或测试范围。

E 解码器与配对图像评价

E.1 固定因果状态预测的解码器配对诊断

该事后配对诊断仅替换 decoder，固定 encoder、校准、已学图及机制，区分 RGB 质量与因果计算。测试情境独立，幅值变化沿用原命令分布，不作方法选型。

训练与测试。 七节点多米诺场景（64×64 彩色图像）种子 5、6、7 各重拟合一份 decoder，供无校准、充分拟合仿射和非线性共用。6000 观测及 896 核验图确定性重放，与保存编码的最大差须小于 2×10^{-4}；不新增独立训练数据，不使用 GT CF、测试状态或图片。仅 decoder 以 ID 重构平方误差训练 40 轮、batch128、Adam 学习率 10^{-4}，取固定末轮，不按测试选型；其他参数和缓存不变。

冻结全部模块后，每种子用 64 个独立事实、7 目标及标准化命令 $\{-0.75, 0.75, -2, 2\}$，每种子/split 含 896 条配对 CF。事实/GT 共享外生情境，各配置共享事实图、命令、GT 及独立读出器。每配置三种子共 5376 条 CF，不是 5376 个独立种子。冻结的普通联合更新仅作同查询参考，不进入 decoder 单独配对。

表 A15: Decoder 配对诊断：误差乘 10^3，报告三种子均值 ± 样本 SD，每种子/split 含 896 条配对查询。上面板比较冻结 D 与相同 ID 图片重拟合的 D'，固定 encoder、校准、图、机制及状态预测；联合更新同时改变读出头和 decoder，仅作参考。可见量 MAE 由独立冻结读出器相对于模拟器激活量计算，GT 图读出误差仅作测量参考。下面板为 $10^3(\mathrm{MSE}_{D'} - \mathrm{MSE}_{D})$，负值更好，括号逐配对列出改善种子数；SD 由逐种子差值计算，不由两组 SD 相减。

配置	ID 图片 MSE↓	幅值偏移 图片 MSE↓	幅值偏移 目标可见量 MAE↓	幅值偏移 非后代效应 MAE↓
无校准，冻结 D	2.259 ± 0.038	1.698 ± 0.069	79.256 ± 3.823	143.379 ± 9.280
无校准，ID 重拟合 D	1.082 ± 0.007	0.854 ± 0.012	16.212 ± 1.226	15.145 ± 1.766
充分拟合仿射，冻结 D	2.241 ± 0.044	1.690 ± 0.076	72.223 ± 4.315	150.861 ± 8.913
充分拟合仿射，ID 重拟合 D	1.037 ± 0.021	0.836 ± 0.029	15.810 ± 1.201	16.719 ± 2.287
非线性校准，冻结 D	2.246 ± 0.044	1.695 ± 0.076	66.577 ± 3.543	155.635 ± 8.886
非线性校准，ID 重拟合 D	1.058 ± 0.019	0.859 ± 0.028	15.394 ± 1.384	18.058 ± 2.758
普通联合更新（参考）	1.047 ± 0.034	0.828 ± 0.020	16.001 ± 1.145	16.625 ± 2.312

配对图片 MSE 差值（改善种子数） 校准配置	ID	幅值偏移
无校准	-1.177 ± 0.039 (3/3)	-0.844 ± 0.058 (3/3)
充分拟合仿射	-1.204 ± 0.028 (3/3)	-0.854 ± 0.047 (3/3)
非线性校准	-1.188 ± 0.027 (3/3)	-0.836 ± 0.047 (3/3)

因果状态不变时的图像收益。 三种配置在两 split 的 RGB 误差均降低，每配对均 3/3 种子改善。非线性 ID 像素 MSE 由 2.246×10^{-3} 降至 1.058×10^{-3}，幅值由 1.695×10^{-3} 降至 0.859×10^{-3}，均值下降 52.90%/49.32%。CF 潜变量、物理状态及数值误差不变，收益归于 decoder 适配，而非图或因果状态改善。

冻结读出器测得幅值目标可见激活 MAE 由 0.06658 降至 0.01539，非后代变化 MAE 由 0.15564 降至 0.01806，并非直接物理状态标签误差。GT 图目标 MAE 约 0.02511 仅作测量参考，既非理论下界，也不证明生成图优于 GT。仿射/无校准重拟合 decoder 在若干指标仍更好，联合更新图像结果也相近，收益不由非线性独占。

配对与成本。 非 decoder 权重完全一致，配对 CF 潜变量最大差 1.78×10^{-15}，状态/效应 NMSE 差均 0。先在种子内平均查询，再报三种子均值、样本 SD 及配对差；配对 SD 不取两组 SD 之差。

每种子渲染 8752 张图：6896 训练重放、1856 事实/测试 CF。测试渲染不计训练干预预算，各组均计校准成本 896 及图发现成本，总计约 0.192 GPU 小时。

E.2 学习型校准的配对反事实图像

本图固定事实索引与命令、共用 decoder；环境有别于正文物理 baseline，不作跨图排名。

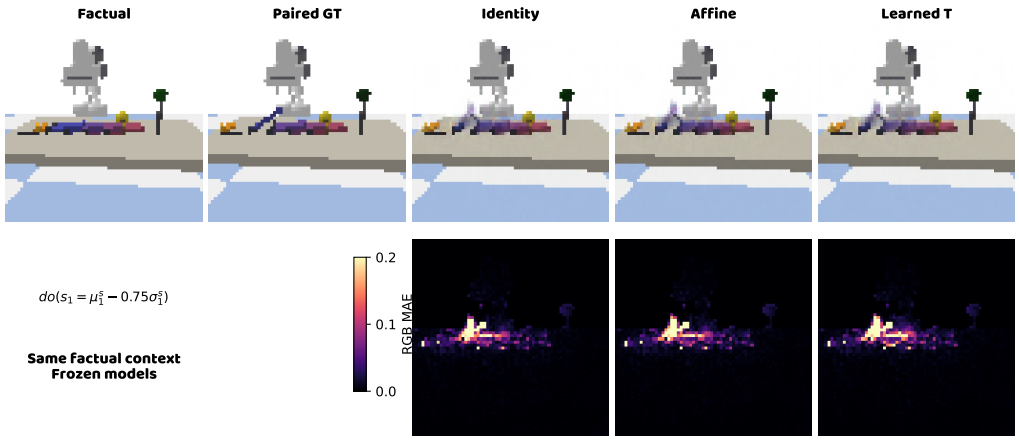


图 A4: 七节点多米诺场景（64×64 彩色图像）的 CF 查询：固定种子 5、事实索引 0、目标 1 及 ID 命令 $u = \mu_1^s - 0.75\sigma_1^s$。三组共用事实情境/decoder，保留各自坐标的事实残差；Learned T 为非线性校准。下排 RGB 绝对误差共用色阶。案例按索引预定，展示独立冻结诊断组，不作单图排名。

F 组件消融与预算对照

F.1 组件消融与干预预算诊断

冻结七节点多米诺场景（64×64 彩色图像）消融以预定训练种子 5、6、7 隔离校准、后代传播及采集策略。

F.1.1 校准究竟修正了什么

固定编码器、解码器、每种子 6000 条观测及 896 条目标干预记录，对编码读数施加逐维变换

$$C_0(z) = z, \qquad C_1(z) = 1.2z + 0.1, \qquad C_2(z) = z + 0.08z^3.$$

应力条件事后设计，但公式、种子、函数族及日程在独立验证前冻结，不搜索失真强度。C_2 严格单调却非轻微尾部扰动，有限有界仿射加 tanh 族不能精确表示其逆。各条件比较恒等、受限正仿射和单调非线性；观测/训练/验证共用 C，命令标签保留训练锚点单位，仅直接目标提供监督。

每种子新增 448 条独立 ID 目标验证，共 1344 条，不拟合或选型。非线性目标读数误差比恒等低 44.93%、88.68%、71.06%（表 A16A），支持操作值/读数对齐而非新增结构信息。正仿射校准不改变标准化后的图片读数（除数值稳定项），但会改变命令对齐 $q_j(u)$（附录 B.6）；逐维可逆映射保持总体条件独立关系。

表 A16: 多米诺组件与预算诊断。A/B 的误差均以 10^{-3} 为单位，报告均值 ± 样本标准差；A 为目标读数 MSE，B 为 ID 反事实 RGB MSE，不跨面板比较数值。浅蓝列标识非线性校准，粗体为行内最小误差；单种子不报标准差。C 为每策略使用的记录数，包含 896 条校准记录；† 表示耗尽预算仍未恢复，不是成功成本。

A. 固定读数条件下的目标校准误差

条件	种子数	无校准	受限正仿射 T	非线性 T
无附加失真	3	23.337 ± 5.417	15.333 ± 2.244	$\mathbf{12.852 \pm 1.690}$
仿射失真	3	114.354 ± 20.126	15.421 ± 2.135	$\mathbf{12.950 \pm 1.909}$
立方失真	3	61.438 ± 15.002	22.149 ± 3.796	$\mathbf{17.781 \pm 2.835}$

B. 相同条件内、共同可执行种子的反事实图像误差

条件	有效/计划	无校准	受限正仿射 T	非线性 T
无附加失真	2/3	$2.2845 \pm .0321$	$\mathbf{2.2604 \pm .0325}$	$2.2683 \pm .0320$
仿射失真	2/3	$2.3372 \pm .0430$	$\mathbf{2.2656 \pm .0317}$	$2.2668 \pm .0325$
立方失真	1/3	2.2671	**2.2156**	2.2223

C. 固定校准与定向规则的采集策略比较

策略	Seed 5	Seed 6	Seed 7	完整图恢复
覆盖选靶	4496	$11696^{\dagger}$	4496	2/3
随机选靶	9896	6296	2696	3/3
固定轮转	2696	2696	2696	3/3

F.1.2 从读数收益到反事实图片

各条件/T 变体共享种子内覆盖轨迹的编码记录，各自学图和机制。输入 $C(E(x))$ 共用坐标包装 decoder $D'(z') = D(C^{-1}(z'))$，已知 C^{-1} 不修补恒等组命令。事实/CF GT 来自相同外生情境，不是模型重构。

每可执行种子用 64 个固定事实、7 目标各两条 ID 命令（训练锚点均值 ±0.75 标准差）。前 8 情境兼作实现检查，不按误差选条件，其余 56 合并计分。仅测试 ID，图未充分定向则阻断，不替代预测或填零。

三种 T 在 C_0/C_1 下均由种子 5、7 通过，C_2 仅 5 通过，通过率 2/3、2/3、1/3。无错误方向，阻断图均留一条未定向边。27 单元中 15 完成图像评价、12 阻断，仅种子 5 跨全部条件/变体共同有效。表 B 只作*各行条件内部*配对，不跨不同分母比较增益。

非线性像素 MSE 比恒等仅降 0.71%、3.01%、1.98%，远小于读数收益，且正仿射点估计始终略低，不支持非线性普遍更优或校准提高恢复率。固定 C_0 非线性表示、图及机制，仅去后代传播使 ID CF MSE 从 2.2683 ± 0.0320 升至 2.9261 ± 0.0060（$\times 10^{-3}$，共同种子 5、7），区分了传播与校准复杂度。

F.1.3 预算成本与采集策略

表 C 三策略共享基座、冻结非线性 T、初图、ID 命令分布及判据，各计 $B_{\text{cal}} = 896$ 后从空干预池采图记录，每批 1800 条、至多 6 批：$B_{\max} = 896 + 10800 = 11696$。各组均作*批量*一致性检查，有别于算法 1 逐项提交。

本三策略对照采用附录 C.2所列 $N = 2600000$ 的图采样流；该节的等记录对照和附录 F.3的同总预算对照复用本组冻结基座、T 和初图，但不复用图样本。种子 5 先采目标 1 时，边 0–1 的反向分数为 0.10640，距阈值 0.15 不足单侧裕度 0.05，故需再采目标 0，总调用为 4496；同总预算组首批分数为 0.05252，已满足单侧判据，总调用为 2696。两者差异来自既定采样流下的实际证据，而非漏计校准成本。

覆盖在种子 6 耗尽预算仍留一条未定向边，11696 不是成功恢复成本；轮转各种子均用 2696 条恢复。结果无覆盖预算优势，固定编号七节点链也不证明轮转普遍最优；仅终态准确率会掩盖成本及失败。

表 C 计*每方法实际使用的记录数*，与目标随机流缓存节省的物理调用分开；三策略共新增 28800 图记录，不重复计缓存回放。映射对照固定数据，表 A19则固定总预算，将无校准组省下的校准预算转给图采集，两类分别统计。

范围与成本。 本 ID 读数失真诊断使用 1344 独立验证、1792CF GT 及 128 事实记录；拟合/学图复用训练记录，无新训练调用。阈值、失真强度和种子预先固定。

F.2 保持项、回放、传播与机制拟合的模块对照

保持、回放、定向传播、事实残差及拟合记录对照共享冻结七节点多米诺场景（64×64 彩色图像）基座与计划种子 5、6、7；配置在评价前固定，不按 OOD 选型。

表 A17: 固定视觉基座下的模块对照。均值 ± 训练种子间样本 SD；粗体仅标各误差列最低点估计，浅蓝行标完整配置。A 使用独立 ID 验证，B/C 复用固定证据与查询。

A. 校准目标与回放：3/3 种子，均乘 10^3 配置	目标读数 MSE↓	配对差（消融 − 完整）
完整配置	13.327 ± 0.648	0.0000 ± 0.0000
去观测保持项	$\mathbf{13.320} \pm 0.647$	-0.0071 ± 0.0016
去累计样本回放	15.245 ± 1.377	1.9174 ± 1.3410
B. 干预后定向传播：3/3 种子，同一固定证据 配置	SHD↓	完整有效图
完整配置	$\mathbf{0.333} \pm 0.577$	2/3
去干预后 Meek 传播	4.333 ± 0.577	0/3
C. 残差与机制拟合：共同有效 2/3 种子，均乘 10^3 配置	CF 像素 MSE↓	非目标编码 NMSE↓
完整配置	2.3077 ± 0.0293	$\mathbf{23.9778} \pm 0.7817$
去后代事实残差	2.7120 ± 0.0189	280.1258 ± 0.5836
非根机制混合全部记录	$\mathbf{2.3067} \pm 0.0333$	24.8983 ± 0.3083
非根机制仅观测拟合	2.3091 ± 0.0292	23.9997 ± 0.8275

A：保持项与累计回放。 固定 encoder、896 目标记录及 1400 步 Adam，仅将保持权重 0.01 改为 0，或以单批替换累计证据、保留模型/优化器状态。9 映射冻结后，共享验证每种子新增 448 独立 ID 记录，共 1344。去回放提高平均目标误差；去保持略降误差却增加训练观测漂移，不支持保持提高目标精度或从漂移推断下游改善。

B：定向传播。 两组共享 PC 初图、校准及全部覆盖证据前缀，仅关闭干预后 Meek 新增方向，保留直接证据和无环/碰撞/一致扩展检查。终态 SHD 从 $0, 1, 0$ 变为 $4, 5, 4$，均无错误方向，完整有效图从 2/3 降至 0/3。这隔离固定证据下传播作用，不代表重采样的在线预算优势。

C：事实残差与机制拟合。 固定图、表示、根池及 decoder，分别将更新后代的事实残差置零、以含自身干预的混合池拟合非根，或仅拟合观测。有效种子共享固定 ID 缓存的 64 情境、7 目标、两命令，构成回顾性配对。seed6 四组均未充分定向，阻断不填零；均值/SD 仅取共同有效种子 5、7。

去事实残差升高像素与编码误差。混合池略降像素均值、略升编码误差，逐种子像素方向不一致；仅观测拟合接近完整组，完整组并非各指标最佳。编码 NMSE 衡量冻结坐标，非独立物理状态误差。混合池只干预节点 0、1，自目标排除仅改变非根节点 1 拟合；仅观测还减少样本量，不能单规则归因。

成本与解释范围。 无新训练环境调用，1344 独立 ID 验证记录另计。B/C 复用证据，各组计 $B_{\text{cal}} = 896$；B 终态图记录数为 $3600, 10800, 3600$。

F.3 组件消融、拟合取舍与干预预算

这些独立配对对照分别检验仿射约束、非线性校准及采集预算，各自定义种子、图提交规则和评测数据，不合并为端到端消融；统计仅作描述，不检验显著性。

实验条件与数据权限。 附录 C.2、D.3、F.2保留图阶段、接口及回放/Meek/残差对照。以下冻结 decoder 校准与同预算采集对照计入校准成本，但不覆盖八场景主表的全部环境/查询。

F.3.1 受限仿射、充分拟合仿射与非线性校准

受限仿射增益为 $[0.75, 1.25]$，充分拟合仅留 $g_j \geq 10^{-6}$，按相同目标平方误差及 $\lambda = 0.01$ 保持损失逐维加权最小二乘；各种子正性边界均未激活。两类仿射及非线性共享 896 记录，无校准不拟合 T。各组以自身观测归一化学图/机制，在独立测试生成前冻结。

表 A18: 冻结解码器下的校准映射对照，误差乘 10^3。上面板为均值 ± 种子间样本 SD 及按种子 5/6/7 排列的 SHD；下面板保留全部逐种子值。状态估计分母 3，CF 为共同有效 2/3。种子 6 各组均保留一条未定向边，CF 阻断（–），不是零误差。

配置	目标 MSE	CF 图像 MSE	SHD
无校准	25.232 ± 3.391	2.1892 ± 0.1470	0/1/0
受限正仿射	16.278 ± 1.553	$\mathbf{2.1651} \pm 0.1441$	0/1/0
充分拟合正仿射	16.278 ± 1.553	$\mathbf{2.1651} \pm 0.1441$	0/1/0
非线性校准	$\mathbf{14.146} \pm 0.850$	2.1726 ± 0.1428	0/1/0

	种子 5		种子 6		种子 7	
配置	目标 MSE	CF 图像 MSE	目标 MSE	CF 图像 MSE	目标 MSE	CF 图像 MSE
无校准	21.971	2.08521	28.740	–	24.984	2.29315
受限仿射	16.069	2.06321	17.925	–	14.840	2.26705
充分拟合仿射	16.069	2.06321	17.925	–	14.840	2.26705
非线性校准	13.869	2.07161	15.100	–	13.468	2.27358

非线性目标误差均值比无校准低 43.94%、比充分拟合仿射低 13.10%；这是均值之比，三种子方向均改善，并非逐种子降幅相同。四组图仍相同，CF 均值仅比无校准低 0.76%，比充分拟合仿射高 0.34%，两有效种子均以仿射更低。状态改善不代表图或图像优势；受限/充分拟合仿射接近，表明增益区间非主要限制。

本组检验直接目标读数纠偏，不分别评价图像目标执行、后代后果及非后代保持。仿射/非线性共享核验值监督，但与不拟合 T 的无校准比较不能完整隔离额外监督和普通更新。非线性可能改变局部关系/残差，与线性机制产生取舍，此解释尚未隔离。跨来源读数见附录 C.2，普通更新与图像语义见附录 D.3。

每种子 7 目标各 64 条独立 ID 验证，共 1344 条；CF 用有效种子 5、7 的 64 事实、7 目标、各两条 ± 0.75 训练标准差命令，共 1792GT 及 128 事实图。3264 测试返回独立于训练预算，预测器不接收 GT 状态。seed6 保留计划分母，不以真图补全。附录 D.2的独立 ID 验证降幅 44.35%/14.54% 另行统计。

F.3.2 计入校准成本的采集效率

种子 5、6、7 各组预算 $B = 11696$。三校准组计 $B_{\text{cal}} = 896$，余 10800 供图采集；无校准全部 11696 用于图。独立随机流按共同目标批配对，缓存复用仍计各组信息预算。每批至多 1800 条并作批量一致性检查；目标分布、PC/定向阈值冻结。停止仅用估计图、预算及可用目标，不读真图。

本同总预算对照的图采样流为 $N = 12600000$，定义及跨组冻结文件对应见附录 C.2。其非线性配置与表 A16C 共享训练种子、基座、T、初图和批量定向代码，但使用不同图样本；种子 5 首批判据差异见附录 F.1。本表非线性配置的总调用数包含 896 条校准记录，而表 A5列出图记录数；比较两表时须同时对齐采样流与计数口径。

表 A19: 同总预算对照。调用数包含校准；星号表示预算耗尽仍未完整定向，不是成功恢复成本。种子顺序均为 5/6/7。

配置	完整真图恢复	实际调用数	SHD
非线性校准＋覆盖选靶	2/3	$2696/11696^{*}/4496$	0/1/0
非线性校准＋随机选靶	3/3	$6296/6296/2696$	0/0/0
非线性校准＋轮转选靶	3/3	$2696/2696/2696$	0/0/0
无校准＋覆盖选靶	2/3	$1800/11696^{*}/3600$	0/1/0

覆盖无预算优势，轮转三种子均以 2696 总调用恢复。seed6 覆盖先采节点 1 再重复节点 0，反向分数 0.1523 高于固定阈值 0.15，双侧规则保留 0–1；此处采用从 0 开始的实现索引。轮转先采节点 0，在单侧证据下完成。轨迹、单/双侧判据及停止共同形成该差异，不代表主动设计普遍劣于轮转。

附录 F.2保留保持、回放、Meek 及拟合的正负结果；目标 MSE、观测漂移和 RGB 方向不一时，不推断所有模块改善所有指标。

G 跨场景系统结果与模型权限

G.1 补充比较的配置与统计

主表的报告配置、运行对应及统计口径见附录 A.3、A.2；本节分别报告 MEC 机制对照、表征模型对照及刚体对照。“–”表示不参与相应协议，不计入排名。校准组另按其图更新规则计分：冻结 decoder、批量定向的 CF 取共同有效种子 5、7；逐项定向、同记录和独立测试的四配置均完成 3/3 种子（附录 D.3）。

物理反事实 ILCM。 该单元格使用种子 42、1280 对训练图片和 256 对验证图片。四目标、两个二值命令、32 个固定情境共 256 个查询，原始浮点解码输出的像素 MSE 为 5.707387×10^{-3}；显示裁剪到 $[0,1]$ 后为 5.696037×10^{-3}，不替代预先指定的原始指标。配对 GT 与本文方法、CausalVAE 归档种子 42 逐数组相同，但主表另外两方法保留各自汇总，ILCM 只代表一个种子。其配对权限、标签用法及仿真预算不同，解码命令响应也很弱，故结果限于该适配，不代表 ILCM 的一般能力上限（附录 A.9）。

MEC 查询组与训练权限。 MEC 机制对照组包含采用学习型 T 的本文方法与无图消融；两者共享冻结的视觉与校准接口。结构学习每场景 8 种子，Balance 采用开发配置；图片与 OOD 另用 300/301 种子，PnP/Gears 完成 2/2，Balance 因第二种子图未定向只完成 1/2。均值和 SD 只在可执行种子上统计，并保留失败分母。MEC 表征模型对照组为各场景种子 300 的 CausalVAE 与 ILCM，使用 RGB64、2400 训练情境和 256 验证情境；前者用观测图片与概念标签，后者用配对图片训练，并在评测时用训练标签作语义匹配与单位标定。两组的 encoder 训练、分辨率、允许输入及归一化读数未完全匹配，分别报告，不与主表合并排名。

图与反事实接口。 MEC 表征模型对照组在读取真图前封存图分数，离散阈值固定 0.1。CausalVAE 在一般 K 概念 Mask Layer 的输入/输出固定目标值（clamp），再调用自身 decoder，与官方四槽位逐元素查询实现不同。ILCM 通过自身条件隐式机制将设定的因果潜变量坐标转换为条件噪声坐标，保留其他噪声并调用自身 decoder；图提取接口通过 ID 正逆往返验证。每场景 32 个固定事实情境、每目标两条 ID 命令，共 Domino448 对、PnP384 对、Balance320 对、Gears384 对。GT 使用同外生噪声重放；RGB 按固定 $[0,1]$ 范围计分，不按单图归一化。

OOD 单位。 MEC 表征模型对照组按训练真概念标准差归一化物理读数，使用 512 个参考情境和 512 个独立模拟器情境；每目标 ID/OOD 各两命令，共 $4K$ 条。机制对照组使用冻结训练坐标与尺度，每命令 2048 个后果。两组均排除直接设定目标，但 NMSE 的读数与协议不同；正文乘 10^3 仅为显示换算。测试分布见附录 A.8。

表征模型对照组的 ILCM 质量诊断。 本组 PnP ILCM 对不同 ID 图片产生近乎相同的表示，语义读数 R^2 接近 0，重构差于训练均值图。两阶段前端对照也未满足 ID 质量要求，因而未评价该配置的 OOD。本组保留实际分数；这一单种子适配的塌缩不代表主表同名方法或其他场景的能力。

刚体条件均值传播对照。 刚体条件均值传播配对对照的训练协议与检查点不同于上述四场景 MEC 表征组。条件均值传播完成 2/3 种子，CausalVAE 完成 3/3；按共同种子 42/314 统计，本文为 0.880 ± 0.016、CausalVAE 为 1.287 ± 0.039（$\times 10^{-3}$）。双方共享 32 初态、256 配对查询，但 CausalVAE 获更多训练概念标签。这些统计仅属于该配对对照，不是表 A1物理无校准汇总或主表学习型校准结果的逐种子依据。本组完整设置及无校准的 RGB64/128 视觉对照见附录 A.9。

表 A20: MEC 机制对照组的分项统计，误差乘 10^3。双种子给均值 ± 样本标准差；括号为可执行/计划种子数。

任务	方法	PnP（2/2）	Balance（1/2）	Gears（2/2）
CF 图片 MSE	本文方法	$1.118 \pm .134$	2.180	$.938 \pm .021$
	无图消融	$2.161 \pm .078$	5.014	$1.859 \pm .093$
ID NMSE	本文方法	$1.771 \pm .433$	2.085	$.729 \pm .228$
	无图消融	57.011 ± 2.039	102.146	$93.292 \pm .179$
OOD NMSE	本文方法	3.461 ± 1.367	4.101	$1.091 \pm .341$
	无图消融	393.035 ± 10.084	700.012	663.595 ± 5.185

表 A21: 多米诺骨牌（RGB 图像）的补充结果（本文方法），误差乘 10^3。原坐标 MSE 与均值图片 MSE 均不替填正文的物理读数 NMSE。

指标	多米诺骨牌（64，8/10）	多米诺骨牌（128，9/10）
反事实图片 MSE	$2.082 \pm .073$	$2.116 \pm .068$
ID 原坐标 MSE	19.382 ± 11.244	16.208 ± 2.870
OOD 原坐标 MSE	32.297 ± 40.164	18.480 ± 2.970
ID 均值图片 MSE	$.370 \pm .025$	$.399 \pm .046$
OOD 均值图片 MSE	$.314 \pm .065$	$.331 \pm .050$

G.2 基线的 ID 诊断与模型选择

系统误差的差距需要结合前端质量与查询响应解释。本节将 MEC 表征模型对照组的评测检查点与各自 ID 训练记录对应，区分训练目标、状态读数和图像响应。各模型的原生验证目标量纲不同，不将其数值作为跨模型 RGB 重构比较。

表 A22: MEC 表征模型对照组的已有 ID 验证与模型选择记录，每行 seed300、$n = 1$。R^2 给节点间范围，不是种子置信区间；选择轮次由完整机制阶段的原生 ID 验证目标确定。诊断只绑定本组检查点，不因数值重合而外推至其他主表运行。

场景	方法	ID 节点 R^2 范围	选择轮次/训练轮次
Domino-MEC	CausalVAE	[0.849, 0.984]	86/100
Domino-MEC	ILCM	[0.220, 0.797]	120/120
PnP-MEC	CausalVAE	[0.919, 0.986]	86/100
PnP-MEC	ILCM	[-0.005, 0.044]	120/120
Balance-MEC	CausalVAE	[0.920, 0.995]	98/100
Balance-MEC	ILCM	[0.118, 0.804]	120/120
Gears-MEC	CausalVAE	[0.902, 0.982]	93/100
Gears-MEC	ILCM	[-0.003, 0.826]	120/120

模型选择与可执行性。 CausalVAE 采用观测专用训练集，ILCM 采用配对图片；语义匹配与单位标定只使用 ID 训练标签。评测检查点均与对应训练记录的 SHA 一致，选择轮次为完整机制阶段 ID 验证目标最低的轮次。四个 ILCM 的最低值均在第 120 轮达到，这只确定了所用模型，不证明优化已经充分收敛。各场景的 no-op 与目标设值代数检查通过，也不等同于生成图片正确响应了命令。

已有 ID 重构与命令响应。 PnP ILCM 的 ID 重构 MSE 为 0.007011，高于训练均值图片的 0.004991；其节点读数 R^2 接近 0。该单种子适配的表示质量不足，不能将其误差解释为 ILCM

的一般能力上限。其余 MEC 模型的上述训练记录未分项给出同口径 ID 重构 MSE 和可见命令响应，不以原生验证目标或代数检查替代这些量。

物理 ILCM 采用图 5B 对应的种子 42 检查点, 按完整机制阶段 ID 目标选取第 120 轮。在 32 个固定情境中，第一块骨牌命令由 0 变为 1 时，未裁剪解码输出的平均绝对变化为 2.28×10^{-5}，配对物理 GT 为 9.91×10^{-3}；设值可执行与可见响应有效仍有明显差别。此为不同预算与监督权限的物理适配，完整设置见附录 A.9。

比较的解释范围。 这些诊断只适用于所列 MEC 和物理运行，不自动覆盖 CAUSAL3D、CausalWorld 或其他同名模型。ILCM 已使用干预配对数据，因此性能差距不能归结为“基线没有干预”。本文的接口对照考察已知核验操作值如何用于校准；数据权限、表示质量和更新范围对系统差距的影响分别解释。

H 相关方法的条件与比较范围

H.1 相关方法的假设与范围

表 A23与 A24展开图 2中的设定：识别未知因素、校准已知变量及选择实验是不同任务。表格比较原方法的输入、监督、模块与图输出，不构成同预算性能排名或首创性证明。

视觉变量与干预信息。 因果表征学习关注具有因果含义的生成因素，不仅是重构能力 (Schölkopf et al., 2021)。CausalVAE 使用概念监督 (Yang et al., 2021)；CITRIS（Causal Identifiability from Temporal Intervened Sequences）使用时序图片与已知目标，iCITRIS 加入瞬时作用 (Lippe et al., 2022; 2023b)；BISCUIT（Causal Representation Learning from Binary Interactions）学习变量与交互的对应 (Lippe et al., 2023a)。隐式潜在因果模型（ILCM）使用未知随机干预前后的配对观测，并支持后续图提取 (Brehmer et al., 2022)。基于干预分布几何性质的识别，在相应设定中可以不要求目标索引与实际值 (Ahuja et al., 2023)。这些方法的学图阶段不同，后续提取不等于缺少图能力。本文使用更强的已知目标身份与实际值监督，校准已有视觉对应，并保留 decoder 坐标。

控制、采集与结构。 独立可控因素（ICF）通过 selectivity 反馈联合学习像素因素与策略，不估计因素邻接图 (Thomas et al., 2018)；Causal Curiosity 学习区分环境因素的行为 (Sontakke et al., 2021)。动作可控分解（ACF）的策略估计用于修正给定转移数据分布，不是新实验采集 (Rodriguez-Sanchez et al., 2025)；视觉因果发现网络（V-CDN）从给定视频学习关键点与结构 (Li et al., 2020)。对于已观测变量，主动策略 (Hauser & Bühlmann, 2014)、主动干预目标选择（AIT）(Scherrer et al., 2021)、因果贝叶斯实验设计（CBED）(Tigas et al., 2022) 和因果摊销主动结构学习（CAASL）(Annadani et al., 2024) 按表中方式选择实验。本文校准按固定轮转采集，仅后续图发现根据当前歧义选靶，设定值来自固定分布。

外推与任务特定结构。 Rep4Ex 使用动作–潜变量不变性进行干预外推 (Saengkyongam et al., 2024)，因此动作信息辅助表征已有先例。Causality-Seeking Agent 从结构化状态–动作轨迹学习上下文相关子图 (Zhao et al., 2025)；奖励导向因果表征学习通过自适应探索恢复任务所需变量与结构 (Yan et al., 2025)；Active Causal Experimentalist（ACE）研究已知图下的机制估计 (Cooper & Velasquez, 2026)。这些专用输出不应被解释为一般能力不足。

本文范围。 本文校准已有语义的像素读数幅度，衔接目标设定、图条件后果与解码。约束式与干预等价类方法提供学图工具 (Colombo & Maathuis, 2014; Hauser & Bühlmann, 2012)；逐维可逆校准不新增可识别性保证。实际收益须由同数据、同预算对照支持。图像反事实与 OOD 后果需要不同的查询和分布定义，勾选既不代表理论保证，也不代表全面优越。

表 A23: 相关方法的假设与信息条件。“概念锚点”指训练时将视觉坐标与已知物理概念对应的监督信息。给定更多信息不代表方法更强；这些条件决定比较是否公平。

工作	输入/样本	节点或变量监督	干预信息与关键条件
CausalVAE (2021)	图像	概念标签	因果层与潜空间编辑；非主动环境采集
ICF (2018)	像素交互轨迹	独立可控因素	操作选择性反馈联合学习表示与策略
Causal Curiosity (2021)	交互轨迹	学习环境因素	可执行实验行为；非标准节点设定值监督
CITRIS (2022)	时序图像	学习潜在变量	已知目标标签，不要求实际值
iCITRIS (2023)	时序图像	学习潜在变量	已知目标，含瞬时效应
BISCUIT (2023)	交互时序图像	学习变量/交互对应	利用二值交互机制
ILCM (2022)	干预前后配对观测	弱监督变量学习	配对且保持外生条件；目标未知
Ahuja 等 (2023)	观测/干预分布组	表征识别	相应设定中目标与实际值不必已知
ACF (2025，预印本)	图像转移三元组	可控因素识别	给定数据；策略估计修正采集分布
V-CDN (2020)	视频图像	关键点与结构学习	给定不同配置数据，无主动选实验
Rep4Ex (2024)	高维特征、动作、结果	表征识别	动作到潜变量的线性结构等假设
Hauser–Bühlmann (2014)	已观测变量	节点给定	候选图等价类上的实验设计
AIT (2021)	已观测变量	节点给定	干预目标空间和生成器给定
CBED (2022)	已观测变量	节点给定	因果模型后验与可执行干预；主动选择设定值
CAASL (2024)	变量/实验历史	节点给定	模拟器预训练，真图参与奖励；主动选择设定值
Causality-Seeking Agent (2025)	结构化状态–动作	状态变量给定	学习上下文及其相关子图
Reward-oriented CRL (2025)	高维混合观测/奖励	学习任务所需变量	线性混合、因果与奖励设定
ACE (2026，预印本)	变量/实验历史	图与节点给定	学习机制与实验策略；主动选择设定值
本文	**RGB 图像与环境实验**	**节点已知、概念锚定**	**已知硬干预目标与设定值；校准后冻结**

阅读方式：同样使用干预数据，不意味着监督条件相同。本文的已知节点与设定值假设强于若干弱监督表征方法，但不要求其特定的时序或事实–干预配对形式。Rep4Ex 与奖励导向方法的高维输入不在此表中等同于图像实验；上下文相关子图也不等同于本文静态结算图。各行来源见附录 H.1。

表 A24: 相关方法的能力与表征约束。✓：原方法明确包含；△：不同形式或后续模块；—：非该方法的组成部分，不表示无法扩展。最后一列说明约束对象，避免把不同任务硬压成同一种校准。

工作	表征学习	主动实验	图的输出/任务	表征利用的约束
CausalVAE	✓	—	静态因果图	概念监督与因果层
ICF	△	✓	非显式图恢复任务	独立可控性与操作选择性
Causal Curiosity	△	✓	非通用显式图恢复	实验区分环境因素
CITRIS	✓	—	△ 后续时间图	干预目标约束
iCITRIS	✓	—	瞬时与时间图	干预目标约束
BISCUIT	✓	—	△ 后续时间图	二值交互机制对应
ILCM	✓	—	△ 训练后提取图	干预前后配对约束
Ahuja 等	✓	—	非主要输出	干预分布几何/恒定性
ACF	✓	—	非显式图恢复任务	动作相对自然转移的效应
V-CDN	✓	—	关键点间结构	给定视频的结构与动力学
Rep4Ex	✓	—	非潜变量图发现任务	动作–表征不变性
Hauser–Bühlmann	—	✓	图等价类/定向	—
AIT	—	✓	接入图学习后端	—
CBED	—	✓	图与机制后验	—
CAASL	—	✓	接入图学习后端	—
Causality-Seeking Agent	△	✓	上下文相关子图	隐含上下文状态
Reward-oriented CRL	✓	✓	任务所需粗粒度结构	奖励相关性
ACE	—	✓	已知图的机制估计	—
本文	△	✓	**静态图估计/未定向边**	**实际设定值下的可逆逐维校准**

限定：主动选择设定值指根据反馈选择或优化已知节点的硬干预数值，不能由连续动作策略直接推断。本文只主动选择目标，数值从预先固定的分布抽样，不优化设定值。本文的 △ 指已有概念身份下的坐标学习与读数校准，不是未知因素解耦；其主动实验仅发生在图发现阶段，校准采集为固定轮转。ICF 与 Causal Curiosity 的因素学习不等同一般潜在结构识别保证，Causality-Seeking Agent 学习的隐含上下文也不是从像素恢复节点。后续图提取并非缺少图发现能力；表中勾选不代表理论保证或同预算实验胜出。